

Московский физико-технический институт
(национальный исследовательский университет)

Ozon E-Cup 2026

Прогнозирование 30-дневной стоимости заказов пользователей

Описание итогового решения

Автор: Сокол Даниил Владимирович

Результат: 86-е место среди 316 команд.

Всего в соревновании участвовали 617 человек. Работа выполнена индивидуально.

Москва, 2026

Содержание

1	Аннотация	3
2	Постановка задачи	3
3	Исходные данные	4
3.1	Единица наблюдения и временной охват	4
3.2	Состав исходных полей	4
3.3	Поведенческая воронка	5
4	Мера качества	6
5	Формирование обучающей выборки	6
5.1	Опорная дата	6
5.2	Календарь обучающих примеров	7
5.3	Размерность обучающей выборки	7
5.4	Предотвращение утечки будущих данных	7
6	Архитектура итогового решения	8
7	Система признаков	9
7.1	Недавняя активность и покупательская воронка	9
7.2	Аналогичный календарный период прошлого года	11
7.3	Годовая история	12
7.4	Периодичность заказов	14
7.5	Денежное поведение	15
7.6	Заполнение отсутствующих значений	17
8	Модели градиентного бустинга	17
9	Контрольный прогноз	18
10	Денежная модель и смешивание прогнозов	19
11	Защита пользователей без истории заказов	19
12	Схема локальной проверки	20
12.1	Разделение пользователей	20

12.2	Условия принятия денежной модели	20
12.3	Условия принятия защитного правила	21
13	Результаты локальной проверки	21
13.1	Денежная модель	21
13.2	Защитное правило	21
13.3	Нулевые и положительные цели	22
13.4	Важность групп признаков	22
14	Итоговый прогноз	23
15	Ограничения интерпретации	23
16	Воспроизведение результата	24
16.1	Программное окружение	24
16.2	Последовательность полного обучения	24
17	Назначение файлов проекта	25
18	Источники	26
A	Проверочные пороги	27
B	Полный перечень признаков	27

1 Аннотация

В работе решается задача индивидуального прогноза суммарной стоимости заказов на ближайшие 30 дней. Для каждого из 250 000 пользователей требуется оценить денежную сумму заказов с 14 февраля по 15 марта 2026 года. Источником служит разреженная история ежедневной активности в Поиске и Каталоге Ozon с 1 января 2025 года по 13 февраля 2026 года.

Итоговый алгоритм состоит из трех последовательно построенных уровней. Первый уровень формирует контрольный прогноз как смесь двух моделей градиентного бустинга над деревьями решений. Они используют показатели недавней активности, прошлогодного календарного периода, годовой истории и периодичности покупок. Второй уровень добавляет отдельную модель с 53 показателями денежного поведения. Она описывает суммы последних покупок, изменение среднего чека, затухающие суммы прошлых заказов и ожидаемое число покупательских циклов в ближайшие 30 дней. Третий уровень применяет заранее проверенное правило к пользователям, у которых в доступной истории не было ни одного дня с заказом.

Все модели обучаются предсказывать $\log(1 + GMV)$. Это соответствует устройству соревновательной меры качества и уменьшает влияние редких очень крупных сумм. Финальный прогноз получается смешиванием оценок в логарифмической шкале. Для активных пользователей вес денежной модели равен 0,4, вес контрольного прогноза равен 0,6. Для пользователей без дней с заказом используется контрольный прогноз. Итоговый файл содержит 250 000 уникальных пользователей, только конечные неотрицательные числа и суммарный прогноз 9 455 203,97 условной денежной единицы.

2 Постановка задачи

Организаторы определяют задачу как прогноз суммарного GMV пользователя в Поиске и Каталоге за следующие 30 дней. Сокращение GMV происходит от английского выражения Gross Merchandise Value. В рамках этого документа GMV означает суммарную стоимость оформленных заказов, записанную в исходных данных. Эта величина относится к обороту заказов и не равна прибыли торговой площадки.

Пусть u обозначает пользователя, t обозначает последний доступный день истории, а $g_{u,d}$ обозначает GMV пользователя u в день d . Целевая величина имеет вид

$$y_{u,t} = \sum_{d=t+1}^{t+30} g_{u,d}. \quad (1)$$

Для итогового прогноза t равно 13 февраля 2026 года. В признаки разрешено включать события с датами до этого дня включительно. Цель охватывает период с 14 февраля

по 15 марта включительно. Каждому пользователю соответствует одно число. Даты отдельных заказов, число будущих заказов и состав корзины отдельно не прогнозируются.

Задача близка к краткосрочной оценке ценности пользователя. Ее сложность связана с неоднородностью покупательского поведения. Часть пользователей совершает покупки регулярно. Другие возвращаются через длинные и нестабильные интервалы. У многих пользователей истинная сумма за следующие 30 дней равна нулю. Распределение положительных сумм имеет длинный правый хвост, поскольку редкие крупные заказы намного превосходят обычные покупки.

3 Исходные данные

3.1 Единица наблюдения и временной охват

Исходный файл содержит более 30 миллионов обезличенных записей о 250 000 пользователях. Одна запись представляет сводку активности пользователя за конкретный день. Данные охватывают период с 1 января 2025 года по 13 февраля 2026 года.

Таблица является разреженной. В ней хранятся наблюдаемые дни активности, поэтому отсутствующий день пользователя не обязан быть отдельной строкой с нулями. Полное построение сетки из всех сочетаний пользователей и календарных дат увеличило бы объем примерно до 100 миллионов строк. В решении такая сетка не создается. События сначала отбираются по нужному временному окну, затем агрегируются по пользователю. После агрегации результат соединяется с полным списком 250 000 пользователей. За счет этого неактивные пользователи сохраняются, а память не расходуется на миллионы пустых строк.

3.2 Состав исходных полей

Названия полей в таблице даны организаторами. Русские определения в таблице ниже соответствуют официальному описанию данных.

Таблица 1: Поля исходной таблицы

Поле	Содержание
event_date	календарная дата наблюдения
user_id	обезличенный идентификатор пользователя
search	признак использования Поиска, принимает значение 0 или 1
cat	признак использования Каталога, принимает значение 0 или 1

Поле	Содержание
has_search_to_cart	признак добавления товара в корзину после использования Поиска
has_search_to_ord	признак покупки после использования Поиска
has_cat_to_cart	признак добавления товара в корзину после использования Каталога
has_cat_to_ord	признак покупки после использования Каталога
search_to_cart	число товаров, добавленных в корзину при использовании Поиска
search_to_ord	число товаров, купленных при использовании Поиска
cat_to_cart	число товаров, добавленных в корзину при использовании Каталога
cat_to_ord	число товаров, купленных при использовании Каталога
gmv_search	стоимость товаров, купленных при использовании Поиска
gmv_cat	стоимость товаров, купленных при использовании Каталога
to_cart	общее число товаров, добавленных в корзину
to_ord	общее число купленных товаров
gmv	общая стоимость купленных товаров
searches	общее число поисковых запросов

Четыре поля, начинающиеся с **has**, не входят в итоговый набор напрямую. Основная конструкция использует соответствующие количества товаров и суммы. Флаги при этом остаются частью исходных данных и могут быть полезны для дальнейших исследований.

3.3 Поведенческая воронка

Поля описывают несколько стадий покупательского пути. Использование Поиска или Каталога отражает верхнюю часть воронки. Добавление в корзину показывает более сильное намерение. Оформленный заказ и его стоимость находятся в нижней части воронки. Такая структура позволяет описывать пользователя через объем действий, переходы между стадиями, давность последней активности и изменение этих величин со временем.

Поиск и Каталог учитываются отдельно, поскольку одинаковая итоговая сумма может возникнуть при разном поведении. Один пользователь приходит с конкретным запросом и быстро оформляет заказ. Другой просматривает Каталог, долго наполняет корзину и покупает реже. Разделение каналов дает модели возможность различать эти траектории.

4 Мера качества

В соревновании используется корень из средней квадратичной логарифмической ошибки. Для n пользователей она рассчитывается по формуле

$$\text{RMSLE} = \sqrt{\frac{1}{n} \sum_{i=1}^n [\log(1 + y_i) - \log(1 + \max(0, \hat{y}_i))]^2}. \quad (2)$$

Здесь y_i является истинным GMV, а $\hat{y}_i$ является прогнозом. Меньшее значение соответствует лучшему решению. Отрицательный прогноз перед расчетом принудительно заменяется нулем.

Логарифм меняет смысл ошибки. Абсолютное отклонение на 100 денежных единиц имеет разную тяжесть для пользователя с ожидаемой суммой 10 и для пользователя с ожидаемой суммой 10 000. Мера сильнее реагирует на относительную ошибку. Ошибки на пользователях с малой истинной суммой, включая ноль, остаются заметными. Редкие очень крупные заказы получают меньшее влияние, чем при обычной среднеквадратичной ошибке в исходной денежной шкале.

По этой причине модели обучаются на преобразованной цели

$$z_{u,t} = \log(1 + y_{u,t}). \quad (3)$$

После получения прогноза $\hat{z}$ выполняется обратное преобразование

$$\hat{y} = \exp(\max(0, \hat{z})) - 1. \quad (4)$$

Ограничение $\hat{z} \geq 0$ гарантирует неотрицательный денежный результат.

5 Формирование обучающей выборки

5.1 Опорная дата

Опорной датой называется день, в который история пользователя мысленно останавливается. Все признаки строятся по событиям не позднее этой даты. Правильный ответ рассчитывается по следующим 30 дням. Такая конструкция превращает один длинный журнал событий в обычную таблицу для обучения модели.

Например, для опорной даты 2 июля 2025 года признаки используют данные до 2 июля включительно. Целевая сумма относится к периоду с 3 июля по 1 августа. События целевого периода не входят в признаки этого же примера.

5.2 Календарь обучающих примеров

В финальном обучении используются восемь опорных дат. Девятая дата нужна для итогового прогноза.

Таблица 2: Опорные даты и целевые периоды

Роль	Опорная дата	Следующие 30 дней
обучение	02.07.2025	03.07.2025 по 01.08.2025
обучение	30.07.2025	31.07.2025 по 29.08.2025
обучение	27.08.2025	28.08.2025 по 26.09.2025
обучение	24.09.2025	25.09.2025 по 24.10.2025
обучение	22.10.2025	23.10.2025 по 21.11.2025
обучение	19.11.2025	20.11.2025 по 19.12.2025
обучение	17.12.2025	18.12.2025 по 16.01.2026
обучение	14.01.2026	15.01.2026 по 13.02.2026
прогноз	13.02.2026	14.02.2026 по 15.03.2026

Интервал между соседними обучающими датами равен 28 дням, а целевой период длится 30 дней. Цели соседних срезов пересекаются на два дня. При этом временная граница каждого примера остается корректной. Будущее одного более раннего среза может стать историей следующего среза, поскольку к следующей опорной дате оно уже наблюдалось.

5.3 Размерность обучающей выборки

Для каждой опорной даты строится ровно одна строка на каждого из 250 000 пользователей. Полная матрица содержит

$$250\,000 \times 8 = 2\,000\,000 \quad (5)$$

обучающих строк. Эти строки не соответствуют двум миллионам разных людей. Один пользователь присутствует до восьми раз, причем состояние его истории и будущий GMV меняются от даты к дате.

Итоговый срез на 13 февраля содержит 250 000 строк без известной цели. После применения модели каждая строка превращается в пару из идентификатора пользователя и прогноза.

5.4 Предотвращение утечки будущих данных

Каждая функция построения признаков получает опорную дату и ограничивает историю этой датой. Цель добавляется отдельным расчетом по дням от $t + 1$ до $t + 30$. Профили

периодичности, денежные показатели и прошлогодний календарный период также завершаются не позднее опорной даты.

После сохранения производных таблиц код проверяет число строк, число уникальных пользователей, схему полей и отсутствие неопределенных или бесконечных значений. Соединение отдельных наборов признаков выполняется по идентификатору пользователя с требованием соответствия один к одному. Исходный порядок строк восстанавливается после каждого соединения.

6 Архитектура итогового решения

Итоговый прогноз строится в четыре вычислительных этапа.

1. Из истории событий создаются показатели пользователя на каждой опорной дате.
2. Две контрольные модели формируют устойчивый исходный прогноз. Первая использует 341 показатель, вторая добавляет 34 показателя периодичности заказов и использует 375 показателей.
3. Модель денежного поведения использует все предыдущие данные и еще 53 показателя сумм покупок. Ее матрица содержит 428 показателей.
4. Контрольный и денежный прогнозы смешиваются. Для пользователей без дней с заказом вес денежной модели обнуляется.

Контрольным прогнозом называется результат, относительно которого проверяется новая денежная модель. Он уже является смесью двух моделей и представляет сильную версию решения, полученную до добавления денежных показателей. Такая организация позволяет принимать новую ветвь только после прямого сравнения с сохраненным контролем на одних и тех же пользователях.

Таблица 3: Уровни итогового алгоритма

Уровень	Размер входа	Результат
годовая	341 показатель	первый прогноз GMV
контрольная модель		
контрольная модель	375 показателей	второй прогноз GMV
периодичности		
контрольная смесь	два прогноза	25% первого и 75% второго в логарифмической шкале
денежная модель	428 показателей	прогноз с подробным описанием сумм покупок
итоговая смесь	два прогноза	60% контроля и 40% денежной модели в логарифмической шкале
защита неактивных пользователей	дни с заказами	возврат к контролю при отсутствии дней с заказом

7 Система признаков

Признаком называется число, которое описывает состояние пользователя на опорную дату и подается модели на вход. Сырая последовательность дней имеет разную длину для разных пользователей. Преобразование в признаки приводит ее к таблице постоянной ширины.

Итоговая денежная модель использует 428 признаков. Они разделены на пять групп.

Таблица 4: Группы признаков денежной модели

Группа	Количество	Доля от 428
недавняя активность и воронка	216	50,5%
аналогичный календарный период прошлого года	58	13,6%
годовая история	67	15,7%
периодичность заказов	34	7,9%
денежное поведение	53	12,4%
всего	428	100,0%

7.1 Недавняя активность и покупательская воронка

Основные признаки недавней активности и покупательской воронки представляют состояние пользователя в последние 180 дней перед опорной датой. Эта группа содержит 216 столбцов. Полный перечень приведён в таблице 12. В него входят объёмы действий, их частота, давность последнего события, отношения между этапами покупательского пути и изменение активности во времени.

Пусть t обозначает опорную дату. Последние 7 дней включают даты от $t - 6$ до t , последние 30 дней от $t - 29$ до t , последние 90 дней от $t - 89$ до t . Эти окна пересекаются. Например, последние 7 дней одновременно входят в 30-дневное и 90-дневное окна. Для каждого окна суммируются использование Поиска и Каталога, поисковые запросы, добавленные в корзину товары, заказанные товары и GMV. Те же расчёты выполняются отдельно для действий после Поиска и после Каталога.

Среднее значение показателя рассчитывается по наблюдаемым строкам пользователя внутри окна. Число активных дней означает число строк, где соответствующая величина была положительной. Поскольку исходная строка описывает пользователя в конкретную дату, это число можно читать как число наблюдаемых дней с данным действием. Например, если за 7 дней у пользователя есть строки с GMV 100, 0 и 400, то сумма GMV равна 500, среднее по трём наблюдаемым строкам равно $500/3 = 166,67$, число дней с положительным GMV равно двум, максимум равен 400.

Пересекающиеся окна показывают общий текущий уровень. Для описания формы истории используются ещё четыре непересекающихся периода. Это дни с 8-го по 30-й до опорной даты, с 31-го по 60-й, с 61-го по 90-й и с 91-го по 180-й. Их длины равны 23, 30, 30 и 90 календарным дням. В каждом периоде заново считаются суммы действий. Для GMV, заказанных товаров и запросов дополнительно считаются число положительных дней и среднее только среди положительных значений.

Такое разбиение позволяет сравнивать соседние части истории без двойного счёта. Если GMV последних 7 дней равен 500, а GMV с 8-го по 30-й день равен 230, то разность среднесуточных темпов составляет

$$\frac{500}{7} - \frac{230}{23} = 61,43. \quad (6)$$

Положительное значение означает, что в самой свежей неделе денежная активность была выше. Аналогичные разности рассчитываются для заказанных товаров, добавлений в корзину и запросов между тремя парами соседних периодов.

Давность события равна расстоянию от опорной даты до последней строки с положительным значением. Отдельные столбцы создаются для GMV, заказов, корзины, запросов, Поиска и Каталога. Если нужного события в 180-дневной истории не было, значение равно 180. Давность связана с суммами, но не повторяет их полностью. Два пользователя могут иметь одинаковый GMV за 30 дней, при этом один купил вчера, а другой 29 дней назад.

Покупательская воронка описывается отношениями между действиями. Например, показатель перехода от корзины к заказу за 30 дней равен

$$\frac{\text{число заказанных товаров за 30 дней}}{\text{число товаров в корзине за 30 дней} + 1}. \quad (7)$$

Единица в знаменателе предотвращает деление на ноль. По тому же принципу рассчитываются заказанные товары на поисковый запрос, доля заказов после Поиска, доля GMV из Поиска и GMV на один заказанный товар.

Три общих столбца содержат GMV, число заказанных товаров и число запросов всех пользователей за последние 30 дней. Внутри одного временного среза они одинаковы для всех строк. Между опорными датами они меняются и передают модели общий уровень активности площадки. Месяц и день недели опорной даты дополняют это описание.

Пользователь	GMV, 7 дн.	GMV, 30 дн.	Давность заказа	Заказы/корзина	Темп GMV
A	500	730	1	0,67	61,43
B	0	120	24	0,20	−5,22
C	0	0	180	0,00	0,00

Рис. 1: Условный фрагмент таблицы основных признаков. Числа приведены для пояснения структуры: одна строка соответствует одному пользователю, столбцы содержат разные характеристики его истории.

7.2 Аналогичный календарный период прошлого года

Признаки аналогичного календарного периода прошлого года описывают поведение пользователя в датах, совпадающих по месяцу и числу с будущим периодом прогноза, но сдвинутых на один год назад. В итоговом срезе требуется предсказать GMV с 14 февраля по 15 марта 2026 года. Историческим аналогом являются даты с 14 февраля по 15 марта 2025 года. Полный список 58 столбцов находится в таблице 13.

Внутри этого 30-дневного прошлогоднего периода каждой дате присваивается номер от 0 до 29. Номер 0 соответствует 14 февраля 2025 года, номер 29 соответствует 15 марта. Период делится на четыре последовательные части: дни с номерами 0–6, 7–14, 15–22 и 23–29. Первая и четвёртая части содержат по 7 дней, вторая и третья по 8. Для каждой части отдельно суммируются GMV, заказанные товары и поисковые запросы. Затем GMV части делится на GMV всех 30 дней, поэтому модель видит, в какой части аналогичного периода пользователь обычно тратил деньги.

Рассмотрим условного пользователя, у которого положительный GMV наблюдался в дни с номерами 2, 8 и 24 и составлял 100, 300 и 600. Суммы четырёх частей будут равны 100, 300, 0 и 600. Их доли в общем GMV 1000 составят 0,10, 0,30, 0 и 0,60. Число дней с GMV равно трём. Эта формулировка означает количество дат, в которые дневная сумма GMV была строго больше нуля. Первый такой день имеет номер 2, последний номер 24, максимум приходится на день 24. Длина активного отрезка с учётом обеих границ равна $24 - 2 + 1 = 23$ дням. Средняя оценка паузы равна $(24 - 2)/(3 - 1) = 11$ дням.

Следующая подгруппа описывает распределение GMV по дням. Средний дневной

GMV рассчитывается как общая сумма, делённая на 30, включая дни без покупок. Для примера это $1000/30 = 33,33$. Также считаются стандартное отклонение, медиана среди положительных дней, сумма трёх крупнейших дней и доли одного и трёх крупнейших дней. Показатель концентрации увеличивается, когда почти весь GMV приходится на небольшое число дат. Нормированная энтропия, напротив, увеличивается при более равномерном распределении суммы по периоду. Отдельно сохраняется GMV суббот и воскресений и его доля в общей сумме.

Два признака сопоставляют личный дневной профиль с общим движением GMV по всем пользователям. Сначала для каждого из 30 дней рассчитывается глобальный GMV площадки. Косинусное сходство сравнивает форму двух последовательностей из 30 чисел. Оно велико, если подъёмы и спады пользователя приходились примерно на те же даты, что и общие подъёмы и спады. Взвешенная интенсивность увеличивается, если личные покупки были сосредоточены в днях с большой долей глобального GMV.

Ещё шесть столбцов описывают 7 и 14 дней перед соответствующей прошлогодней опорной датой. Для этих окон суммируются GMV, заказанные товары и запросы. Они показывают, входил ли пользователь в прошлогодний период уже активным. Категория наполненности профиля принимает значение 0 при нулевом GMV, 1 при одном положительном дне, 2 при двух или трёх и 3 при четырёх и более положительных днях.

Полный прошлогодний профиль доступен для январского обучающего среза и итогового февральского среза. В ранних обучающих срезах соответствующих дат ещё нет в исходной истории, поэтому 58 столбцов заполняются нулями. Это ограничение фактической сборки модели учитывается при интерпретации результатов.

Пользователь	GMV год назад	Дней с GMV	Доля части 1	Доля части 4	Пик, день	Выходные, доля
A	1000	3	0,10	0,60	24	0,60
B	420	6	0,48	0,00	5	0,14
C	0	0	0,00	0,00	−1	0,00

Рис. 2: Условный фрагмент таблицы признаков аналогичного календарного периода прошлого года. Значение −1 показывает отсутствие даты максимума или первой покупки при нулевом профиле.

7.3 Годовая история

Признаки годовой истории строятся по доступному периоду длиной до 365 дней перед опорной датой. Они описывают долгосрочный масштаб и изменение поведения. Группа содержит 67 столбцов, перечисленных в таблице 14.

Первая подгруппа состоит из сумм за всю доступную историю. Для GMV, заказанных и добавленных в корзину товаров, запросов, использования Поиска и Каталога, а также отдельных действий каналов рассчитывается сумма за период до 365 дней. Те же показатели отдельно суммируются в старой части истории с 181-го по 365-й день до опор-

ной даты. Последние 180 дней в этот второй расчёт не входят. Для GMV, заказов, корзины и запросов также считается количество строк с положительным значением.

Долгосрочная форма активности строится из двенадцати непересекающихся 30-дневных блоков. Блок 0 охватывает последние 30 дней, блок 1 предшествующие 30 дней, блок 11 содержит дни с 331-го по 360-й до опорной даты. Общие годовые суммы используются до 365 дней, а двенадцать блоков покрывают 360 самых свежих дней. Для каждого блока рассчитываются три суммы: GMV, заказанные товары и запросы.

Пусть B_k обозначает сумму выбранного показателя в блоке k , где $k = 0$ соответствует самому свежему блоку. Перед сравнением применяется преобразование $b_k = \log(1 + B_k)$. Двенадцать чисел b_k превращаются в среднее, стандартное отклонение, медиану, максимум и долю блоков с положительной исходной суммой. Логарифм ограничивает влияние единичных крупных покупок и оставляет нулевой блок равным нулю.

Из этих же блоков строятся признаки изменения. Среднее трёх свежих блоков сравнивается со средним трёх предыдущих и со средним девяти более старых. Среднее шести свежих сравнивается с шестью старыми. Например, если GMV трёх свежих блоков равен 900, 600 и 300, а в трёх предыдущих блоках он равен 200, 200 и 200, то разность в логарифмической шкале составляет

$$\frac{\log 901 + \log 601 + \log 301}{3} - \log 201 \approx 1,00. \quad (8)$$

Положительное значение указывает на рост свежего уровня относительно предыдущего периода. Линейный наклон рассчитывается по всем двенадцати значениям. Номер блока увеличивается по направлению в прошлое, поэтому положительный наклон означает, что старые блоки в среднем крупнее свежих, а отрицательный соответствует росту к опорной дате.

Последняя подгруппа описывает заказы в календарном времени. Сохраняются давность последнего заказа и последнего положительного GMV, расстояние между первым и последним днями с заказом, средняя и стандартная пауза между такими днями. GMV делится на число заказанных товаров с добавлением единицы в знаменатель. Отдельно рассчитываются доли последних 90 дней в годовом GMV и годовом числе заказанных товаров. Реальная длина доступной истории L хранится отдельным столбцом.

Как и прошлогодний профиль, годовая группа полностью заполнена для январского обучающего среза и итогового среза. В более ранних строках финальной матрицы эти столбцы равны нулю, поскольку схема подготовки сохраняет одинаковую ширину таблицы для всех опорных дат.

Пользователь	GMV, 365 дн.	GMV, дни 181–365	Активных блоков	Разность 3/3	Давность заказа	Доля GMV, 90 дн.
A	7200	2500	0,83	1,00	3	0,42
B	900	700	0,25	−0,38	71	0,08
C	0	0	0,00	0,00	365	0,00

Рис. 3: Условный фрагмент таблицы годовых признаков. Столбец «Активных блоков» показывает долю из двенадцати 30-дневных блоков с положительной суммой.

7.4 Периодичность заказов

Признаки периодичности заказов описывают последовательность дат, в которые пользователь заказывал хотя бы один товар. Группа содержит 34 столбца. Их полный состав приведён в таблице 15.

Сначала все исходные строки одного пользователя за одну дату объединяются. Число заказанных товаров в этот день суммируется. После объединения пользователь с заказами 3 января, 12 января и 1 февраля имеет три покупательских дня, даже если 12 января в исходном файле было несколько строк. Обозначим упорядоченные даты через $d_1 < d_2 < \dots < d_m$, а число заказанных товаров в эти дни через $q_1, \dots, q_m$. Пауза $g_i = d_i - d_{i-1}$ рассчитывается в календарных днях.

Первая подгруппа описывает сами покупательские дни. В неё входят их число m , сумма $\sum_i q_i$, среднее, стандартное отклонение и максимум q_i , число товаров в последнем дне, доля дней с $q_i > 1$ и расстояние $d_m - d_1$. Если в трёх днях было заказано 1, 3 и 1 товар, то общее число равно 5, среднее равно $5/3 = 1,67$, доля дней с несколькими товарами равна $1/3$.

Вторая подгруппа описывает паузы. Для дат 3 января, 12 января и 1 февраля они равны 9 и 20 дням. Модель получает последнюю, предпоследнюю и третью с конца паузы, если они существуют. По всему набору пауз рассчитываются среднее, медиана, стандартное отклонение, минимум, максимум, первая и третья четверти, межквартильный размах, среднее трёх последних и среднее пяти последних пауз. Коэффициент вариации равен стандартному отклонению, делённому на среднюю паузу с нижней границей знаменателя 1.

Третья подгруппа сравнивает обычный ритм с текущим состоянием. Пусть опорная дата равна 13 февраля. Для последней покупки 1 февраля давность r равна 12 дням. Медиана пауз 9 и 20 дней при линейном расчёте равна 14,5. Отношение давности к медиане равно $12/14,5 = 0,83$, разность равна $-2,5$, а оценка дней до типичного следующего цикла равна $14,5 - 12 = 2,5$. Число прошедших полных циклов рассчитывается как целая часть $r/14,5$ и в этом примере равно нулю.

Регулярность задается величиной

$$R = \frac{1}{1 + s_g / \max(\bar{g}, 1)}, \quad (9)$$

где $\bar{g}$ является средней паузой, а s_g является её стандартным отклонением. Для пауз 9 и 20 дней среднее равно 14,5, стандартное отклонение равно 5,5, поэтому $R \approx 0,725$. Чем ближе значение к единице, тем меньше относительный разброс пауз.

Распределение заказанных товаров по дням недели описывается семью долями p_k . Нормированная энтропия равна $-\sum_k p_k \log p_k / \log 7$. Она близка к нулю, если почти все товары заказывались в один день недели, и растёт при более равномерном распределении. Рядом сохраняются максимальная доля дня недели и номер преобладающего дня от 0 до 6.

Если у пользователя нет заказов, число покупательских дней и суммы равны нулю, а недоступные паузы получают длину доступной истории. При единственном покупательском дне разброс пауз равен нулю. Такое заполнение сохраняет пользователя в таблице и одновременно сообщает модели, что оценить его обычный ритм по истории невозможно.

Пользователь	Дней с заказом	Всего товаров	Медиана паузы	Давность	Давность/медиана	Регулярность
A	3	5	14,5	12	0,83	0,725
B	8	11	28,0	43	1,54	0,810
C	0	0	365,0	365	1,00	1,000

Рис. 4: Условный фрагмент таблицы признаков периодичности заказов. Заполнение пользователя С отражает отсутствие наблюдаемого ритма, а не регулярные покупки раз в 365 дней.

7.5 Денежное поведение

Денежные признаки описывают величину покупок и её изменение в последовательности покупательских дней. Группа содержит 53 столбца, перечисленных в таблице 16. Здесь покупательским днём называется дата, в которую у пользователя был положительный GMV или хотя бы один заказанный товар.

Сначала события за доступные 365 дней объединяются по паре «пользователь и дата». Для каждого покупательского дня рассчитываются общий GMV v_j , число заказанных товаров q_j , GMV из Поиска, GMV из Каталога и стоимость одного заказанного товара $a_j = v_j / \max(q_j, 1)$. Затем вся последовательность одного пользователя сжимается в одну строку итоговой таблицы. Выражение «уровень пользователя» означает именно эту детализацию данных: одна строка соответствует одному пользователю, а каждый столбец содержит характеристику всей его истории. Оно не обозначает рейтинг, категорию или ценность пользователя.

Первая подгруппа описывает распределение денежных сумм. Для v_j и a_j рассчитываются среднее, стандартное отклонение, медиана, максимум, первая и третья четверти и коэффициент вариации. Допустим, три покупательских дня произошли 40, 10 и 3 дня назад. Их GMV равен 200, 500 и 900, а число заказанных товаров равно 2, 1 и 3. Тогда стоимость товара в эти дни равна 100, 500 и 300. Средний GMV покупательского дня равен $1600/3 = 533,33$, медиана равна 500, максимум равен 900.

Вторая подгруппа сохраняет порядок покупок. В отдельные столбцы записываются GMV, число товаров и стоимость товара последнего, предпоследнего и третьего с конца покупательского дня. Для последних 3, 5 и 10 дней рассчитываются средние. Если покупательских дней меньше требуемого числа, среднее строится по всем доступным дням. Логарифмические разности сравнивают сумму GMV последних трёх дней с предыдущими тремя, средний GMV последних трёх со средним за всю историю и среднюю стоимость товара последних трёх с предыдущими тремя. Доля последних трёх дней равна их суммарному GMV, делённому на GMV всей доступной истории.

Третья подгруппа учитывает одновременно сумму и давность. Для каждого покупательского дня возраст age_j равен числу дней от него до опорной даты. Затухающая сумма задаётся формулой

$$D_h = \sum_j v_j \exp\left(-\frac{age_j}{h}\right). \quad (10)$$

Используются масштабы h в 7, 14, 30, 60 и 90 дней. Формула применяется отдельно к GMV и числу заказанных товаров. В рассмотренном примере затухающий GMV с $h = 30$ равен

$$900e^{-3/30} + 500e^{-10/30} + 200e^{-40/30} \approx 1225,34. \quad (11)$$

Свежая покупка на 900 сохраняет почти полный вес, покупка 40 дней назад влияет слабее.

Четвёртая подгруппа строит прямые оценки ближайших 30 дней. Пусть $\tilde{g}$ является медианной паузой между покупательскими днями, а m их числом. Ожидаемое число циклов равно

$$C_{30} = \min\left(\frac{30}{\max(\tilde{g}, 1)}, 30\right), \quad (12)$$

и рассчитывается только при $m \geq 2$. Для пауз 30 и 7 дней медиана равна 18,5, поэтому $C_{30} = 30/18,5 \approx 1,62$. Средний GMV последних пяти доступных покупательских дней в примере равен 533,33. Циклическая оценка будущего GMV составляет примерно $1,62 \times 533,33 = 864,86$.

Отдельная оценка продолжает средний денежный темп доступной истории:

$$E_{30} = 30 \frac{\sum_j GMV_j}{L}, \quad (13)$$

где L является числом доступных календарных дней. Столбец с техническим именем `money_expected_orders_by_rate_30d` рассчитывается как $30m/L$. Он оценивает число покупательских дней, хотя его имя в коде содержит слово `orders`. Ещё од-

на оценка умножает циклический GMV на $\exp[-r/\max(\tilde{g}, 1)]$, где r является давностью последней покупки. Для примера множитель равен $e^{-3/18,5}$, а скорректированная сумма составляет около 735 денежных единиц.

Последняя подгруппа разделяет денежный источник. По пяти последним покупательским дням рассчитываются доли GMV из Поиска и Каталога. Доля Поиска сравнивается с её значением за всю доступную историю. Модель получает информацию о том, изменился ли привычный канал совершения покупок.

Пользователь	Средний GMV дня	Последний GMV	GMV с затуханием, 30	Циклов, 30 дн.	GMV по циклу	Доля Поиска, 5 дн.
A	533,33	900	1225,34	1,62	864,86	0,70
B	180,00	120	205,17	0,75	135,00	0,25
C	0,00	0	0,00	0,00	0,00	0,00

Рис. 5: Условный фрагмент таблицы денежных признаков. После расчёта последовательность покупательских дней преобразуется в одну строку на пользователя.

7.6 Заполнение отсутствующих значений

Пользователь сохраняется в каждом срезе, даже если в рассматриваемом окне не было событий. Суммы и количества в таком случае равны нулю. Давность получает предельное значение, соответствующее доступной длине истории. Неопределенный разброс при единственном событии заменяется нулем. Паузы, которые нельзя вычислить, получают длину доступной истории там, где это соответствует смыслу признака.

После сборки все показатели приводятся к 32-разрядным вещественным числам. Код отдельно проверяет отсутствие пропусков, неопределенных чисел и бесконечностей. Это снижает расход памяти при матрице из двух миллионов строк.

8 Модели градиентного бустинга

Во всех трех моделях используется CatBoostRegressor. CatBoost является реализацией градиентного бустинга над деревьями решений. Модель строит деревья последовательно. Каждое следующее дерево уменьшает ошибку текущей суммы деревьев. В итоговой задаче все входы числовые, поэтому специальные механизмы обработки категориальных полей не используются.

Целью обучения служит $\log(1 + GMV)$. Функция потерь является обычной средне-квадратичной ошибкой в этой шкале. Ее квадратный корень совпадает с соревновательной мерой до обратного преобразования и ограничения отрицательных прогнозов.

Общие параметры зафиксированы в коде:

Таблица 5: Параметры моделей CatBoost

Параметр	Значение
скорость обучения	0,05
глубина дерева	6
штраф на величину листьев	10,0
случайная сила разбиений	0,5
начальное состояние генератора	42
число вычислительных потоков	все доступные

Число итераций отличается. Годовая контрольная модель обучается 1061 итерацию. Контрольная модель периодичности использует 1171 итерацию. Денежная модель использует 776 итераций. Последнее число найдено на проверочной части с механизмом ранней остановки. Ранней остановкой здесь называется прекращение обучения после 150 итераций без улучшения ошибки. В финальном переобучении механизм отключается, а найденное число итераций фиксируется заранее.

Идентификатор пользователя в признаки не включается. Модель изучает состояние и историю поведения. Отдельный номер клиента не несет для нее самостоятельной информации.

9 Контрольный прогноз

Первая контрольная модель получает 216 основных, 58 прошлогодних и 67 годовых признаков. Общая ширина составляет 341. Вторая контрольная модель добавляет 34 показателя периодичности заказов, поэтому ее ширина равна 375.

Обе модели обучаются на двух миллионах строк восьми опорных дат. Их прогнозы обозначим p_A и p_C . Контрольный результат строится в логарифмической шкале:

$$p_{ctrl} = \exp(0,25 \log(1 + p_A) + 0,75 \log(1 + p_C)) - 1. \quad (14)$$

Такое смешивание соответствует геометрическому усреднению величин $1 + p$. Оно согласуется с мерой качества, поскольку расстояние между прогнозом и целью также измеряется после $\log(1 + x)$. Большой вес модели периодичности отражает результат локальной проверки. Добавление этой группы снизило RMSLE с 1,663101 до 1,661949. Относительное уменьшение ошибки составило 0,0693%.

Контрольный прогноз сохраняется для каждого пользователя. Он используется как самостоятельный результат, как исходная точка при проверке денежной модели и как запасной прогноз для пользователей без истории заказов.

10 Денежная модель и смешивание прогнозов

Денежная модель использует 428 признаков. Она получает все показатели контрольной модели периодичности и 53 новых показателя денежных сумм. Обозначим ее прогноз через p_M .

Финальный вариант для пользователя с историей заказов равен

$$p_{mix} = \exp(0,60 \log(1 + p_{ctrl}) + 0,40 \log(1 + p_M)) - 1. \quad (15)$$

Вес 0,40 выбирался по сетке от 0 до 1 с шагом 0,05. Выбор выполнялся только на настроенной группе пользователей. Подтверждающая группа применялась после фиксации веса.

Самостоятельная денежная модель дала на настроенной группе RMSLE 1,674985 при ошибке контроля 1,674456. Это ухудшение на 0,0316%. На подтверждающей группе денежная модель достигла 1,661676 при контроле 1,661949, что соответствует улучшению на 0,0164%. Различие знака показывает, что один итог по одной группе пользователей недостаточен для выбора модели. Смесь снизила ошибку на 0,0303% в настроенной группе и на 0,0511% в подтверждающей, поэтому оказалась устойчивее отдельного денежного прогноза.

11 Защита пользователей без истории заказов

Пользователь считается неактивным для защитного правила, если за всю доступную историю длиной до 365 дней у него нет ни одного дня с положительным числом заказанных товаров. Правило меняет только вес денежной модели:

$$w_u = \begin{cases} 0, & \text{если число дней с заказами равно нулю,} \\ 0,4, & \text{если имеется хотя бы один день с заказом.} \end{cases} \quad (16)$$

Итоговый прогноз записывается как

$$p_u = \exp((1 - w_u) \log(1 + p_{ctrl,u}) + w_u \log(1 + p_{M,u})) - 1. \quad (17)$$

Денежные показатели пользователя без покупок состоят преимущественно из нулей. Их добавление создает слабую и нестабильную поправку. Контрольная модель при этом уже использует поиск, корзину, давность действий и общую активность. Проверенное правило сохраняет денежную поправку для пользователей с наблюдаемыми покупками и возвращает контрольный прогноз для остальных.

В итоговом срезе правило затронуло 31 971 пользователя, или 12,7884% от тестов-

вой выборки. Оно не присваивает ноль автоматически. Пользователь получает контрольную оценку, которая может быть положительной благодаря поисковой активности, корзине и другим признакам.

12 Схема локальной проверки

12.1 Разделение пользователей

Для проверки денежной модели используется опорная дата 14 января 2026 года. Ее 250 000 пользователей делятся на три непересекающиеся группы:

- 200 000 пользователей входят в обучение;
- 25 000 пользователей образуют настроечную группу;
- 25 000 пользователей образуют подтверждающую группу.

К 200 000 январских строк добавляются шесть полных исторических срезов от 2 июля до 19 ноября 2025 года. Проверочная обучающая матрица содержит

$$6 \times 250\,000 + 200\,000 = 1\,700\,000 \quad (18)$$

строк. Срез 17 декабря на этом этапе не используется. После принятия гипотезы финальная денежная модель переобучается на всех семи исторических срезах и полном январском срезе, то есть на двух миллионах строк.

Настроечная группа определяет число итераций и вес денежной модели. Подтверждающая группа не участвует в выборе этих значений. Она один раз проверяет сохранение улучшения на других пользователях той же даты.

12.2 Условия принятия денежной модели

Гипотеза принимается при одновременном выполнении четырех условий. Вес денежной модели должен быть положительным. Ошибка смеси должна уменьшиться на настроечной группе. Улучшение на подтверждающей группе должно составить как минимум 0,0003. Доля положительных улучшений при повторной выборке пользователей с возвращением должна быть не ниже 0,80.

При повторной выборке из подтверждающей группы 500 раз создается новая выборка того же размера. Один пользователь может попасть в нее несколько раз, другой может не попасть. Для каждой выборки вычисляется разность ошибок контроля и смеси. Этот расчет оценивает устойчивость знака улучшения к составу пользователей.

12.3 Условия принятия защитного правила

Правило для пользователей без заказов сначала проверяется на настроечной группе, затем без изменения переносится на подтверждающую. Для него выполняется 2000 повторных выборок. Правило принимается, если улучшение положительно на обеих группах.

13 Результаты локальной проверки

13.1 Денежная модель

Таблица 6: Ошибка денежной модели и ее смеси с контролем

Группа	Контроль	Денежная модель	Смесь 60/40
настроечная	1,674456	1,674985	1,673949
подтверждающая	1,661949	1,661676	1,661099

Улучшение смеси относительно контроля составило 0,000507 на настроечной группе, или 0,0303%, и 0,000850 на подтверждающей, или 0,0511%. Для подтверждающей группы 95-процентный интервал абсолютного улучшения при повторной выборке находится от 0,000289 до 0,001394. Относительно контрольного RMSLE его границы составляют примерно 0,0174% и 0,0839%. Положительный знак получен в 99,8% повторов.

13.2 Защитное правило

Таблица 7: Влияние защитного правила

Группа	Пользователи	Без заказов	Смесь	После правила
настроечная	25 000	3 414	1,673949	1,673942
подтверждающая	25 000	3 472	1,661099	1,661050

На настроечной группе защитное правило снизило RMSLE с 1,673949 до 1,673942. Абсолютное улучшение равно 0,000008, относительное примерно 0,00045%. На подтверждающей группе ошибка уменьшилась с 1,661099 до 1,661050, то есть на 0,000049 или 0,00296%. Интервал абсолютного улучшения при 2000 повторных выборках находится от 0,000014 до 0,000086. В относительном выражении это примерно от 0,00084% до 0,00520%. Положительный знак получен в 99,8% повторов. Масштаб результата соответствует узкому правилу, которое изменяет прогноз только для части пользователей.

13.3 Нулевые и положительные цели

В подтверждающей группе 45,848% пользователей имеют нулевой GMV в следующих 30 днях. После защитного правила корень из средней квадратичной логарифмической ошибки равен 1,5682 среди нулевых целей и 1,7358 среди положительных целей.

Нулевые цели дают около 40,9% общей суммы квадратов логарифмических ошибок. Положительные цели дают около 59,1%. Источниками высокой ошибки служат оба типа наблюдений. Модель одновременно решает задачу будущей активности и задачу размера покупки. Ошибки на положительных суммах остаются большей частью общей квадратичной ошибки.

Доля строго нулевых прогнозов в итоговом файле равна 0,1376%, хотя доля нулевых целей на локальной январской проверке близка к 46%. Это свойство регрессии по логарифму. Модель чаще выдает небольшую положительную оценку, чем точный ноль. Защитное правило также не является классификатором нуля, поскольку возвращает контрольный денежный прогноз.

13.4 Важность групп признаков

Важность извлечена из проверочной денежной модели CatBoost, обученной при выборе числа итераций и веса смеси. Сумма важностей всех 428 признаков нормирована к 100.

Таблица 8: Суммарная важность групп в денежной модели

Группа	Суммарная важность
денежное поведение	63,785
недавняя активность и воронка	20,141
периодичность заказов	14,397
годовая история	1,514
аналогичный календарный период прошлого года	0,163

Наибольшую важность получили затухающее число заказанных товаров за 90 дней, оценка ожидаемого числа покупательских дней по годовому темпу, разброс пауз между заказами, затухающее число заказов за 60 дней и доля GMV последних трех покупательских дней. Среди основных признаков выделяются давность любой наблюдаемой активности и число поисковых запросов за 7 дней.

Эти значения показывают, какие разбиения деревьев чаще влияли на прогноз внутри конкретной проверочной модели. Они не являются причинной оценкой. Связанные признаки могут делить важность между собой, а малая важность группы не доказывает ее бесполезность при удалении.

14 Итоговый прогноз

Финальный файл `submission_monetary_cadence_inactive_guard.csv` содержит два столбца. Поле `user_id` хранит идентификатор пользователя, поле `predict` хранит прогноз GMV.

Таблица 9: Проверенные свойства итогового файла

Показатель	Значение
число строк	250 000
число уникальных пользователей	250 000
пользователи без дней с заказом	31 971
доля пользователей без дней с заказом	12,7884%
сумма прогнозов	9 455 203,97
средний прогноз	37,8208
медианный прогноз	6,9209
доля нулевых прогнозов	0,1376%

Автоматические проверки подтверждают отсутствие дубликатов пользователей, пропусков, бесконечных и отрицательных значений. Для активных пользователей сохраненная оценка точно совпадает со смесью контроля и денежной модели с весом 0,4. Для пользователей без дней с заказом она точно совпадает с контрольным прогнозом.

15 Ограничения интерпретации

Локальная проверка денежной модели разделяет пользователей внутри одного январского среза. Она хорошо проверяет перенос на других пользователей при той же опорной дате, но не измеряет перенос с января на февраль и март. Календарный сдвиг, праздники и изменение общего уровня спроса могут изменить соотношение моделей.

Целевые периоды соседних обучающих срезов пересекаются на два дня. Это увеличивает сходство соседних примеров. Проверочные пользователи отделены по идентификатору, поэтому один и тот же пользователь не попадает одновременно в настроенную и подтверждающую группы январского среза. Исторические строки этих пользователей входят в полные ранние срезы при проверочном обучении. Следовательно, разделение нельзя трактовать как строгую проверку на полностью новых пользователях.

Прошлогодние и годовые признаки заполнены содержательными значениями только для январского и итогового срезов. В ранних строках их столбцы равны нулю. Модель может использовать сам факт доступности длинной истории как признак даты. Такая схема воспроизводит фактический код решения, но создает различие между ранней и поздней частью обучения.

Показатели прошлого года получили малую суммарную важность в денежной модели. Их роль может сохраняться в контрольных моделях и у отдельных пользователей. Текущая проверка не изолирует их вклад после появления денежных признаков.

Почти половина целей на январской проверке равна нулю, а строго нулевые прогнозы встречаются редко. Отдельная модель вероятности покупки могла бы увеличить число нулевых ответов. Ранее проверенные варианты такого разложения не входят в выбранное решение. Текущий алгоритм остается одной регрессией по логарифму с узким защитным правилом.

Публичная часть рейтинга соревнования охватывает 20% пользователей, закрытая часть охватывает 80%. Улучшение публичного результата является наблюдением на меньшей части теста и не гарантирует сохранение порядка на закрытой части. Точное значение рейтинговой ошибки выбранного файла в артефактах проекта не сохранено, поэтому в отчет включены воспроизводимые локальные показатели и свойства самого файла.

16 Воспроизведение результата

16.1 Программное окружение

Проект рассчитан на Python 3.12. Зависимости перечислены в `requirements.txt`. Окружение создается следующими командами:

```
python3.12 -m venv .venv
.venv/bin/pip install -r requirements.txt
```

Крупные производные таблицы по умолчанию сохраняются в `Library/Caches/Ozon_GMV` внутри домашнего каталога пользователя. Это снижает риск выгрузки больших файлов из локального хранилища macOS. Каталог можно изменить переменной `OZON_GMV_RUNTIME_DIR`.

16.2 Последовательность полного обучения

Первый шаг строит исходные срезы, обучает две контрольные модели и сохраняет контрольный прогноз:

```
python -m src.final_solution --retrain
```

Второй шаг готовит денежные профили, выполняет проверочное обучение и после принятия гипотезы переобучает денежную модель на двух миллионах строк:

```
from src.monetary_experiment import (
    prepare_experiment_inputs,
```

```

    run_validation_experiment,
    run_final_training,
)

base_paths, monetary_paths = prepare_experiment_inputs()
validation = run_validation_experiment(
    paths=base_paths,
    money_paths=monetary_paths,
)
final = run_final_training(
    paths=base_paths,
    money_paths=monetary_paths,
)

```

Третий шаг повторно проверяет защитное правило и создает выбранный файл:

```
python -m src.inactive_guard
```

Ноутбук `notebooks/final_solution.ipynb` выполняет быструю сборку файла из сохраненных прогнозов и проверяет его схему. Полное обучение вынесено в модули, поскольку требует больше памяти и времени, чем обычная сборка итогового файла.

17 Назначение файлов проекта

Таблица 10: Файлы итогового решения

Файл	Назначение
<code>src/config.py</code>	пути, длины временных окон, начальное состояние генератора и каталоги результатов
<code>src/data.py</code>	чтение исходного файла и получение полного списка пользователей
<code>src/features.py</code>	216 показателей недавней активности, воронки, давности и динамики
<code>src/seasonality.py</code>	показатели аналогичного календарного периода прошлого года
<code>src/annual_features.py</code>	67 показателей годовой истории
<code>src/cadence_features.py</code>	34 показателя периодичности дней с заказами
<code>src/monetary_cadence.py</code>	53 показателя денежных сумм и покупательских циклов

Файл	Назначение
src/models.py	единая конфигурация CatBoost и обратное преобразование прогноза
src/final_solution.py	подготовка входов, две контрольные модели, смесь 25/75 и проверки файлов
src/monetary_experiment.py	проверка денежной модели, выбор веса 0,4 и финальное переобучение
src/inactive_guard.py	проверка правила для пользователей без заказов и создание итогового файла
notebooks/final_solution.ipynb	короткая воспроизводимая сборка выбранного файла
artifacts/final_solution	модели и прогнозы контрольного уровня
artifacts/monetary_cadence	денежная модель, проверочные прогнозы, важности и сводки
artifacts/inactive_guard	показатели проверки защитного правила
submissions/submission_monetary_cadence_inactive_guard.csv	выбранный итоговый прогноз

18 Источники

1. ODS.ai. E-Cup 2026, задача «Ценность пользователей поиска». Постановка задачи и мера качества.
2. ODS.ai. Описание полей исходного набора данных.
3. L. Prokhorenkova и соавторы. Статья с описанием устройства CatBoost, 2018.
4. Исходный код и сохраненные результаты проекта.

А Проверочные пороги

Таблица 11: Зафиксированные условия денежного эксперимента

Настройка	Значение
максимум проверочных итераций	1600
ожидание ранней остановки	150 итераций
шаг веса денежной модели	0,05
минимальное улучшение на подтверждающей группе	0,0003
минимальная доля положительных повторов	0,80
полученное число финальных итераций	776
полученный вес денежной модели	0,40

В Полный перечень признаков

Пять таблиц ниже содержат все 428 столбцов итоговой денежной модели. Техническое имя воспроизводит название в матрице обучения. Русское описание передаёт смысл расчёта. Формула показывает точную операцию, выполненную кодом.

Во всех таблицах t обозначает опорную дату. Окно W_7 содержит даты от $t - 6$ до t , W_{30} от $t - 29$ до t , W_{90} от $t - 89$ до t , W_{365} от $t - 364$ до t . Запись $W_{8:30}$ означает дни с 8-го по 30-й до опорной даты. Аналогично читаются $W_{31:60}$, $W_{61:90}$, $W_{91:180}$ и $W_{181:365}$.

$S_x(W)$ обозначает сумму исходного показателя x в окне W . $N_{obs}(W)$ является числом наблюдаемых строк пользователя, а $N_x^+(W)$ числом строк, где $x > 0$. Обозначения gmv , ord , $cart$ и $queries$ соответствуют GMV, заказанным товарам, товарам в корзине и поисковым запросам. Дополнительный индекс s относится к Поиску, индекс c к Каталогу.

H^{LY} обозначает прошлогодний календарный аналог будущего 30-дневного периода. В формулах этой группы v_d является дневным GMV пользователя, G_d общим GMV всех пользователей, $w_d = G_d / \sum_d G_d$ долей конкретного дня в общем GMV. Буква V без индекса означает сумму личного GMV за весь прошлогодний период.

В годовых формулах B_k является суммой показателя в 30-дневном блоке k , $b_k = \log(1 + B_k)$. Блок 0 является самым свежим, блок 11 самым старым. В формулах периодичности d_i обозначает упорядоченные дни с заказами, q_i число заказанных товаров в день d_i , $g_i = d_i - d_{i-1}$ паузу, $r = t - d_m$ текущую давность. Доли p_k описывают распределение заказанных товаров по семи дням недели.

В денежных формулах v_j означает GMV покупательского дня, q_j число заказанных товаров, $a_j = v_j / \max(q_j, 1)$ стоимость одного товара, age_j давность дня, m число покупательских дней, L доступную длину истории. Обозначения $Q_{0.25}$ и $Q_{0.75}$ соответствуют первой и третьей четвертям распределения, sd стандартному отклонению, $clip$ ограничению значения заданными границами. Единица или 10^{-6} в знаменателе предотвращает

деление на ноль.

Таблица 12: Основные признаки недавней активности и покупательской воронки

Название в коде	Смысл на русском	Расчёт
anchor_month	номер месяца опорной даты	$month(t)$
anchor_weekday	номер дня недели опорной даты, от 0 до 6	$weekday(t)$
avg_order_value_30d	GMV на заказанный товар за последние 30 дней	$S_{gmV}(W_{30})/[S_{ord}(W_{30}) + 1]$
avg_order_value_7d	GMV на заказанный товар за последние 7 дней	$S_{gmV}(W_7)/[S_{ord}(W_7) + 1]$
avg_order_value_90d	GMV на заказанный товар за последние 90 дней	$S_{gmV}(W_{90})/[S_{ord}(W_{90}) + 1]$
cart_to_order_rate_30d	заказанные товары относительно добавленных в корзину за последние 30 дней	$S_{ord}(W_{30})/[S_{cart}(W_{30}) + 1]$
cart_to_order_rate_7d	заказанные товары относительно добавленных в корзину за последние 7 дней	$S_{ord}(W_7)/[S_{cart}(W_7) + 1]$
cart_to_order_rate_90d	заказанные товары относительно добавленных в корзину за последние 90 дней	$S_{ord}(W_{90})/[S_{cart}(W_{90}) + 1]$
cat_sum_30d	сумма показателя «использование Каталога» за последние 30 дней	$S_{cat}(W_{30})$
cat_sum_31_60d	сумма показателя «использование Каталога» с 31-го по 60-й день до опорной даты	$S_{cat}(W_{31:60})$
cat_sum_61_90d	сумма показателя «использование Каталога» с 61-го по 90-й день до опорной даты	$S_{cat}(W_{61:90})$
cat_sum_7d	сумма показателя «использование Каталога» за последние 7 дней	$S_{cat}(W_7)$
cat_sum_8_30d	сумма показателя «использование Каталога» с 8-го по 30-й день до опорной даты	$S_{cat}(W_{8:30})$
cat_sum_90d	сумма показателя «использование Каталога» за последние 90 дней	$S_{cat}(W_{90})$
cat_sum_91_180d	сумма показателя «использование Каталога» с 91-го по 180-й день до опорной даты	$S_{cat}(W_{91:180})$
cat_to_cart_sum_30d	сумма показателя «товары в корзине после Каталога» за последние 30 дней	$S_{cart,c}(W_{30})$
cat_to_cart_sum_31_60d	сумма показателя «товары в корзине после Каталога» с 31-го по 60-й день до опорной даты	$S_{cart,c}(W_{31:60})$
cat_to_cart_sum_61_90d	сумма показателя «товары в корзине после Каталога» с 61-го по 90-й день до опорной даты	$S_{cart,c}(W_{61:90})$
cat_to_cart_sum_7d	сумма показателя «товары в корзине после Каталога» за последние 7 дней	$S_{cart,c}(W_7)$
cat_to_cart_sum_8_30d	сумма показателя «товары в корзине после Каталога» с 8-го по 30-й день до опорной даты	$S_{cart,c}(W_{8:30})$
cat_to_cart_sum_90d	сумма показателя «товары в корзине после Каталога» за последние 90 дней	$S_{cart,c}(W_{90})$
cat_to_cart_sum_91_180d	сумма показателя «товары в корзине после Каталога» с 91-го по 180-й день до опорной даты	$S_{cart,c}(W_{91:180})$
cat_to_ord_sum_30d	сумма показателя «заказанные товары после Каталога» за последние 30 дней	$S_{ord,c}(W_{30})$
cat_to_ord_sum_31_60d	сумма показателя «заказанные товары после Каталога» с 31-го по 60-й день до опорной даты	$S_{ord,c}(W_{31:60})$
cat_to_ord_sum_61_90d	сумма показателя «заказанные товары после Каталога» с 61-го по 90-й день до опорной даты	$S_{ord,c}(W_{61:90})$
cat_to_ord_sum_7d	сумма показателя «заказанные товары после Каталога» за последние 7 дней	$S_{ord,c}(W_7)$
cat_to_ord_sum_8_30d	сумма показателя «заказанные товары после Каталога» с 8-го по 30-й день до опорной даты	$S_{ord,c}(W_{8:30})$

Продолжение на следующей странице

Продолжение таблицы 12

Название в коде	Смысл на русском	Расчёт
cat_to_ord_sum_90d	сумма показателя «заказанные товары после Каталога» за последние 90 дней	$S_{ord,c}(W_{90})$
cat_to_ord_sum_91_180d	сумма показателя «заказанные товары после Каталога» с 91-го по 180-й день до опорной даты	$S_{ord,c}(W_{91:180})$
catalog_cart_to_order_rate_30d	заказы после Каталога относительно корзины после Каталога за последние 30 дней	$S_{ord,c}(W_{30})/[S_{cart,c}(W_{30}) + 1]$
catalog_cart_to_order_rate_7d	заказы после Каталога относительно корзины после Каталога за последние 7 дней	$S_{ord,c}(W_7)/[S_{cart,c}(W_7) + 1]$
catalog_cart_to_order_rate_90d	заказы после Каталога относительно корзины после Каталога за последние 90 дней	$S_{ord,c}(W_{90})/[S_{cart,c}(W_{90}) + 1]$
days_since_any_observed_activity	число дней с последней наблюдаемой активностью любого вида	$t - \max(d_{obs})$
days_since_cat	число дней с последнего положительного значения «использование Каталога»	$t - \max(d : cat_d > 0)$
days_since_gmv	число дней с последнего положительного значения «GMV»	$t - \max(d : gmv_d > 0)$
days_since_search	число дней с последнего положительного значения «использование Поиска»	$t - \max(d : search_d > 0)$
days_since_searches	число дней с последнего положительного значения «поисковые запросы»	$t - \max(d : queries_d > 0)$
days_since_to_cart	число дней с последнего положительного значения «товары, добавленные в корзину»	$t - \max(d : cart_d > 0)$
days_since_to_ord	число дней с последнего положительного значения «заказанные товары»	$t - \max(d : ord_d > 0)$
global_gmv_sum_30d	сумма показателя «GMV» по всем пользователям за 30 дней	$\sum_u S_{gmv}^u(W_{30})$
global_orders_sum_30d	сумма показателя «заказанные товары» по всем пользователям за 30 дней	$\sum_u S_{ord}^u(W_{30})$
global_searches_sum_30d	сумма показателя «поисковые запросы» по всем пользователям за 30 дней	$\sum_u S_{queries}^u(W_{30})$
gmv_active_days_30d	число строк с положительным значением «GMV» за последние 30 дней	$N_{gmv}^+(W_{30})$
gmv_active_days_31_60d	число строк с положительным значением «GMV» с 31-го по 60-й день до опорной даты	$N_{gmv}^+(W_{31:60})$
gmv_active_days_61_90d	число строк с положительным значением «GMV» с 61-го по 90-й день до опорной даты	$N_{gmv}^+(W_{61:90})$
gmv_active_days_7d	число строк с положительным значением «GMV» за последние 7 дней	$N_{gmv}^+(W_7)$
gmv_active_days_8_30d	число строк с положительным значением «GMV» с 8-го по 30-й день до опорной даты	$N_{gmv}^+(W_{8:30})$
gmv_active_days_90d	число строк с положительным значением «GMV» за последние 90 дней	$N_{gmv}^+(W_{90})$
gmv_active_days_91_180d	число строк с положительным значением «GMV» с 91-го по 180-й день до опорной даты	$N_{gmv}^+(W_{91:180})$
gmv_cat_sum_30d	сумма показателя «GMV из Каталога» за последние 30 дней	$S_{gmv,c}(W_{30})$
gmv_cat_sum_31_60d	сумма показателя «GMV из Каталога» с 31-го по 60-й день до опорной даты	$S_{gmv,c}(W_{31:60})$
gmv_cat_sum_61_90d	сумма показателя «GMV из Каталога» с 61-го по 90-й день до опорной даты	$S_{gmv,c}(W_{61:90})$
gmv_cat_sum_7d	сумма показателя «GMV из Каталога» за последние 7 дней	$S_{gmv,c}(W_7)$

Продолжение на следующей странице

Продолжение таблицы 12

Название в коде	Смысл на русском	Расчёт
gmv_cat_sum_8_30d	сумма показателя «GMV из Каталога» с 8-го по 30-й день до опорной даты	$S_{gmv,c}(W_{8:30})$
gmv_cat_sum_90d	сумма показателя «GMV из Каталога» за последние 90 дней	$S_{gmv,c}(W_{90})$
gmv_cat_sum_91_180d	сумма показателя «GMV из Каталога» с 91-го по 180-й день до опорной даты	$S_{gmv,c}(W_{91:180})$
gmv_daily_trend_31_60_vs_61_90	разность среднесуточного показателя «GMV» между периодами с 31-го по 60-й день до опорной даты и с 61-го по 90-й день до опорной даты	$S_{gmv}(W_{31:60})/30 - S_{gmv}(W_{61:90})/30$
gmv_daily_trend_7_vs_8_30	разность среднесуточного показателя «GMV» между периодами за последние 7 дней и с 8-го по 30-й день до опорной даты	$S_{gmv}(W_7)/7 - S_{gmv}(W_{8:30})/23$
gmv_daily_trend_8_30_vs_31_60	разность среднесуточного показателя «GMV» между периодами с 8-го по 30-й день до опорной даты и с 31-го по 60-й день до опорной даты	$S_{gmv}(W_{8:30})/23 - S_{gmv}(W_{31:60})/30$
gmv_day_share_of_observed_180d	доля наблюдаемых строк за 180 дней, в которых был положительный GMV за последние 90 дней	$N^+_{gmv}(W_{90})/[N_{obs}(W_{180}) + 1]$
gmv_max_30d	максимальное значение «GMV» за последние 30 дней	$\max_{d \in W_{30}} x_d$
gmv_max_7d	максимальное значение «GMV» за последние 7 дней	$\max_{d \in W_7} x_d$
gmv_max_90d	максимальное значение «GMV» за последние 90 дней	$\max_{d \in W_{90}} x_d$
gmv_mean_active_30d	среднее значение «GMV» по наблюдаемым строкам за последние 30 дней	$\text{mean}_{d \in W_{30} \cap obs} x_d$
gmv_mean_active_7d	среднее значение «GMV» по наблюдаемым строкам за последние 7 дней	$\text{mean}_{d \in W_7 \cap obs} x_d$
gmv_mean_active_90d	среднее значение «GMV» по наблюдаемым строкам за последние 90 дней	$\text{mean}_{d \in W_{90} \cap obs} x_d$
gmv_mean_positive_31_60d	среднее положительное значение «GMV» с 31-го по 60-й день до опорной даты	$S_{gmv}(W_{31:60})/N^+_{gmv}(W_{31:60})$
gmv_mean_positive_61_90d	среднее положительное значение «GMV» с 61-го по 90-й день до опорной даты	$S_{gmv}(W_{61:90})/N^+_{gmv}(W_{61:90})$
gmv_mean_positive_8_30d	среднее положительное значение «GMV» с 8-го по 30-й день до опорной даты	$S_{gmv}(W_{8:30})/N^+_{gmv}(W_{8:30})$
gmv_mean_positive_91_180d	среднее положительное значение «GMV» с 91-го по 180-й день до опорной даты	$S_{gmv}(W_{91:180})/N^+_{gmv}(W_{91:180})$
gmv_per_gmv_day_30d	GMV на строку с положительным GMV за последние 30 дней	$S_{gmv}(W_{30})/[N^+_{gmv}(W_{30}) + 1]$
gmv_per_gmv_day_7d	GMV на строку с положительным GMV за последние 7 дней	$S_{gmv}(W_7)/[N^+_{gmv}(W_7) + 1]$
gmv_per_gmv_day_90d	GMV на строку с положительным GMV за последние 90 дней	$S_{gmv}(W_{90})/[N^+_{gmv}(W_{90}) + 1]$
gmv_recent_intensity_30_vs_90	интенсивность GMV последних 30 дней относительно 90 дней	$30S_{gmv}(W_{30})/[S_{gmv}(W_{90}) + 1]$
gmv_recent_intensity_7_vs_30	интенсивность GMV последних 7 дней относительно 30 дней	$7S_{gmv}(W_7)/[S_{gmv}(W_{30}) + 1]$
gmv_search_sum_30d	сумма показателя «GMV из Поиска» за последние 30 дней	$S_{gmv,s}(W_{30})$
gmv_search_sum_31_60d	сумма показателя «GMV из Поиска» с 31-го по 60-й день до опорной даты	$S_{gmv,s}(W_{31:60})$

Продолжение на следующей странице

Продолжение таблицы 12

Название в коде	Смысл на русском	Расчёт
gmv_search_sum_61_90d	сумма показателя «GMV из Поиска» с 61-го по 90-й день до опорной даты	$S_{gmv,s}(W_{61:90})$
gmv_search_sum_7d	сумма показателя «GMV из Поиска» за последние 7 дней	$S_{gmv,s}(W_7)$
gmv_search_sum_8_30d	сумма показателя «GMV из Поиска» с 8-го по 30-й день до опорной даты	$S_{gmv,s}(W_{8:30})$
gmv_search_sum_90d	сумма показателя «GMV из Поиска» за последние 90 дней	$S_{gmv,s}(W_{90})$
gmv_search_sum_91_180d	сумма показателя «GMV из Поиска» с 91-го по 180-й день до опорной даты	$S_{gmv,s}(W_{91:180})$
gmv_sum_30d	сумма показателя «GMV» за последние 30 дней	$S_{gmv}(W_{30})$
gmv_sum_31_60d	сумма показателя «GMV» с 31-го по 60-й день до опорной даты	$S_{gmv}(W_{31:60})$
gmv_sum_61_90d	сумма показателя «GMV» с 61-го по 90-й день до опорной даты	$S_{gmv}(W_{61:90})$
gmv_sum_7d	сумма показателя «GMV» за последние 7 дней	$S_{gmv}(W_7)$
gmv_sum_8_30d	сумма показателя «GMV» с 8-го по 30-й день до опорной даты	$S_{gmv}(W_{8:30})$
gmv_sum_90d	сумма показателя «GMV» за последние 90 дней	$S_{gmv}(W_{90})$
gmv_sum_91_180d	сумма показателя «GMV» с 91-го по 180-й день до опорной даты	$S_{gmv}(W_{91:180})$
gmv_trend_30_vs_90	отклонение GMV последних 30 дней от трети 90-дневной суммы	$S_{gmv}(W_{30}) - S_{gmv}(W_{90})/3$
observed_active_days_180d	число наблюдаемых строк пользователя за 180 дней	$N_{obs}(W_{180})$
observed_day_density_31_60d	доля календарных дней с наблюдаемой строкой с 31-го по 60-й день до опорной даты	$N_{obs}(W_{31:60})/30$
observed_day_density_61_90d	доля календарных дней с наблюдаемой строкой с 61-го по 90-й день до опорной даты	$N_{obs}(W_{61:90})/30$
observed_day_density_8_30d	доля календарных дней с наблюдаемой строкой с 8-го по 30-й день до опорной даты	$N_{obs}(W_{8:30})/23$
observed_day_density_91_180d	доля календарных дней с наблюдаемой строкой с 91-го по 180-й день до опорной даты	$N_{obs}(W_{91:180})/90$
observed_days_31_60d	число наблюдаемых строк с 31-го по 60-й день до опорной даты	$N_{obs}(W_{31:60})$
observed_days_61_90d	число наблюдаемых строк с 61-го по 90-й день до опорной даты	$N_{obs}(W_{61:90})$
observed_days_8_30d	число наблюдаемых строк с 8-го по 30-й день до опорной даты	$N_{obs}(W_{8:30})$
observed_days_91_180d	число наблюдаемых строк с 91-го по 180-й день до опорной даты	$N_{obs}(W_{91:180})$
observed_history_span_days	длина периода от первой наблюдаемой строки до опорной даты	$t - \min(d_{obs}) + 1$
order_day_share_of_observed_180d	доля наблюдаемых строк за 180 дней, в которых были заказы за последние 90 дней	$N^+_{ord}(W_{90})/[N_{obs}(W_{180}) + 1]$
orders_per_order_day_30d	заказанные товары на строку с заказами за последние 30 дней	$S_{ord}(W_{30})/[N^+_{ord}(W_{30}) + 1]$
orders_per_order_day_7d	заказанные товары на строку с заказами за последние 7 дней	$S_{ord}(W_7)/[N^+_{ord}(W_7) + 1]$
orders_per_order_day_90d	заказанные товары на строку с заказами за последние 90 дней	$S_{ord}(W_{90})/[N^+_{ord}(W_{90}) + 1]$
orders_trend_30_vs_90	отклонение заказанных товаров последних 30 дней от трети 90-дневной суммы	$S_{ord}(W_{30}) - S_{ord}(W_{90})/3$

Продолжение на следующей странице

Продолжение таблицы 12

Название в коде	Смысл на русском	Расчёт
search_cart_to_order_rate_30d	заказы после Поиска относительно корзины после Поиска за 30 дней	$S_{ord,s}(W_{30})/[S_{cart,s}(W_{30}) + 1]$
search_channel_to_cart_rate_30d	товары в корзине после Поиска на поисковый запрос за последние 30 дней	$S_{cart,s}(W_{30})/[S_{queries}(W_{30}) + 1]$
search_channel_to_cart_rate_7d	товары в корзине после Поиска на поисковый запрос за последние 7 дней	$S_{cart,s}(W_7)/[S_{queries}(W_7) + 1]$
search_channel_to_cart_rate_90d	товары в корзине после Поиска на поисковый запрос за последние 90 дней	$S_{cart,s}(W_{90})/[S_{queries}(W_{90}) + 1]$
search_channel_to_order_rate_30d	заказы после Поиска на поисковый запрос за последние 30 дней	$S_{ord,s}(W_{30})/[S_{queries}(W_{30}) + 1]$
search_channel_to_order_rate_7d	заказы после Поиска на поисковый запрос за последние 7 дней	$S_{ord,s}(W_7)/[S_{queries}(W_7) + 1]$
search_channel_to_order_rate_90d	заказы после Поиска на поисковый запрос за последние 90 дней	$S_{ord,s}(W_{90})/[S_{queries}(W_{90}) + 1]$
search_gmv_share_30d	доля GMV из Поиска за последние 30 дней	$S_{gmv,s}(W_{30})/[S_{gmv}(W_{30}) + 1]$
search_gmv_share_7d	доля GMV из Поиска за последние 7 дней	$S_{gmv,s}(W_7)/[S_{gmv}(W_7) + 1]$
search_gmv_share_90d	доля GMV из Поиска за последние 90 дней	$S_{gmv,s}(W_{90})/[S_{gmv}(W_{90}) + 1]$
search_order_share_30d	доля заказанных товаров после Поиска за последние 30 дней	$S_{ord,s}(W_{30})/[S_{ord}(W_{30}) + 1]$
search_order_share_7d	доля заказанных товаров после Поиска за последние 7 дней	$S_{ord,s}(W_7)/[S_{ord}(W_7) + 1]$
search_order_share_90d	доля заказанных товаров после Поиска за последние 90 дней	$S_{ord,s}(W_{90})/[S_{ord}(W_{90}) + 1]$
search_recent_intensity_30_vs_90	интенсивность запросов последних 30 дней относительно 90 дней	$30S_{queries}(W_{30})/[S_{queries}(W_{90}) + 1]$
search_recent_intensity_7_vs_30	интенсивность запросов последних 7 дней относительно 30 дней	$7S_{queries}(W_7)/[S_{queries}(W_{30}) + 1]$
search_sum_30d	сумма показателя «использование Поиска» за последние 30 дней	$S_{search}(W_{30})$
search_sum_31_60d	сумма показателя «использование Поиска» с 31-го по 60-й день до опорной даты	$S_{search}(W_{31:60})$
search_sum_61_90d	сумма показателя «использование Поиска» с 61-го по 90-й день до опорной даты	$S_{search}(W_{61:90})$
search_sum_7d	сумма показателя «использование Поиска» за последние 7 дней	$S_{search}(W_7)$
search_sum_8_30d	сумма показателя «использование Поиска» с 8-го по 30-й день до опорной даты	$S_{search}(W_{8:30})$
search_sum_90d	сумма показателя «использование Поиска» за последние 90 дней	$S_{search}(W_{90})$
search_sum_91_180d	сумма показателя «использование Поиска» с 91-го по 180-й день до опорной даты	$S_{search}(W_{91:180})$
search_to_cart_rate_30d	добавленные в корзину товары на поисковый запрос за 30 дней	$S_{cart}(W_{30})/[S_{queries}(W_{30}) + 1]$
search_to_cart_sum_30d	сумма показателя «товары в корзине после Поиска» за последние 30 дней	$S_{cart,s}(W_{30})$
search_to_cart_sum_31_60d	сумма показателя «товары в корзине после Поиска» с 31-го по 60-й день до опорной даты	$S_{cart,s}(W_{31:60})$
search_to_cart_sum_61_90d	сумма показателя «товары в корзине после Поиска» с 61-го по 90-й день до опорной даты	$S_{cart,s}(W_{61:90})$
search_to_cart_sum_7d	сумма показателя «товары в корзине после Поиска» за последние 7 дней	$S_{cart,s}(W_7)$
search_to_cart_sum_8_30d	сумма показателя «товары в корзине после Поиска» с 8-го по 30-й день до опорной даты	$S_{cart,s}(W_{8:30})$

Продолжение на следующей странице

Продолжение таблицы 12

Название в коде	Смысл на русском	Расчёт
search_to_cart_sum_90d	сумма показателя «товары в корзине после Поиска» за последние 90 дней	$S_{cart,s}(W_{90})$
search_to_cart_sum_91_180d	сумма показателя «товары в корзине после Поиска» с 91-го по 180-й день до опорной даты	$S_{cart,s}(W_{91:180})$
search_to_ord_sum_30d	сумма показателя «заказанные товары после Поиска» за последние 30 дней	$S_{ord,s}(W_{30})$
search_to_ord_sum_31_60d	сумма показателя «заказанные товары после Поиска» с 31-го по 60-й день до опорной даты	$S_{ord,s}(W_{31:60})$
search_to_ord_sum_61_90d	сумма показателя «заказанные товары после Поиска» с 61-го по 90-й день до опорной даты	$S_{ord,s}(W_{61:90})$
search_to_ord_sum_7d	сумма показателя «заказанные товары после Поиска» за последние 7 дней	$S_{ord,s}(W_7)$
search_to_ord_sum_8_30d	сумма показателя «заказанные товары после Поиска» с 8-го по 30-й день до опорной даты	$S_{ord,s}(W_{8:30})$
search_to_ord_sum_90d	сумма показателя «заказанные товары после Поиска» за последние 90 дней	$S_{ord,s}(W_{90})$
search_to_ord_sum_91_180d	сумма показателя «заказанные товары после Поиска» с 91-го по 180-й день до опорной даты	$S_{ord,s}(W_{91:180})$
search_to_order_rate_30d	заказанные товары на поисковый запрос за 30 дней	$S_{ord}(W_{30})/[S_{queries}(W_{30}) + 1]$
searches_active_days_30d	число строк с положительным значением «поисковые запросы» за последние 30 дней	$N^+_{queries}(W_{30})$
searches_active_days_31_60d	число строк с положительным значением «поисковые запросы» с 31-го по 60-й день до опорной даты	$N^+_{queries}(W_{31:60})$
searches_active_days_61_90d	число строк с положительным значением «поисковые запросы» с 61-го по 90-й день до опорной даты	$N^+_{queries}(W_{61:90})$
searches_active_days_7d	число строк с положительным значением «поисковые запросы» за последние 7 дней	$N^+_{queries}(W_7)$
searches_active_days_8_30d	число строк с положительным значением «поисковые запросы» с 8-го по 30-й день до опорной даты	$N^+_{queries}(W_{8:30})$
searches_active_days_90d	число строк с положительным значением «поисковые запросы» за последние 90 дней	$N^+_{queries}(W_{90})$
searches_active_days_91_180d	число строк с положительным значением «поисковые запросы» с 91-го по 180-й день до опорной даты	$N^+_{queries}(W_{91:180})$
searches_daily_trend_31_60_vs_61_90	разность среднесуточного показателя «поисковые запросы» между периодами с 31-го по 60-й день до опорной даты и с 61-го по 90-й день до опорной даты	$S_{queries}(W_{31:60})/30 - S_{queries}(W_{61:90})/30$
searches_daily_trend_7_vs_8_30	разность среднесуточного показателя «поисковые запросы» между периодами за последние 7 дней и с 8-го по 30-й день до опорной даты	$S_{queries}(W_7)/7 - S_{queries}(W_{8:30})/23$
searches_daily_trend_8_30_vs_31_60	разность среднесуточного показателя «поисковые запросы» между периодами с 8-го по 30-й день до опорной даты и с 31-го по 60-й день до опорной даты	$S_{queries}(W_{8:30})/23 - S_{queries}(W_{31:60})/30$
searches_max_30d	максимальное значение «поисковые запросы» за последние 30 дней	$\max_{d \in W_{30}} x_d$
searches_max_7d	максимальное значение «поисковые запросы» за последние 7 дней	$\max_{d \in W_7} x_d$

Продолжение на следующей странице

Продолжение таблицы 12

Название в коде	Смысл на русском	Расчёт
searches_max_90d	максимальное значение «поисковые запросы» за последние 90 дней	$\max_{d \in W_{90}} x_d$
searches_mean_active_30d	среднее значение «поисковые запросы» по наблюдаемым строкам за последние 30 дней	$\text{mean}_{d \in W_{30} \cap \text{obs}} x_d$
searches_mean_active_7d	среднее значение «поисковые запросы» по наблюдаемым строкам за последние 7 дней	$\text{mean}_{d \in W_7 \cap \text{obs}} x_d$
searches_mean_active_90d	среднее значение «поисковые запросы» по наблюдаемым строкам за последние 90 дней	$\text{mean}_{d \in W_{90} \cap \text{obs}} x_d$
searches_mean_positive_31_60d	среднее положительное значение «поисковые запросы» с 31-го по 60-й день до опорной даты	$S_{\text{queries}}(W_{31:60})/N^+_{\text{queries}}(W_{31:60})$
searches_mean_positive_61_90d	среднее положительное значение «поисковые запросы» с 61-го по 90-й день до опорной даты	$S_{\text{queries}}(W_{61:90})/N^+_{\text{queries}}(W_{61:90})$
searches_mean_positive_8_30d	среднее положительное значение «поисковые запросы» с 8-го по 30-й день до опорной даты	$S_{\text{queries}}(W_{8:30})/N^+_{\text{queries}}(W_{8:30})$
searches_mean_positive_91_180d	среднее положительное значение «поисковые запросы» с 91-го по 180-й день до опорной даты	$S_{\text{queries}}(W_{91:180})/N^+_{\text{queries}}(W_{91:180})$
searches_sum_30d	сумма показателя «поисковые запросы» за последние 30 дней	$S_{\text{queries}}(W_{30})$
searches_sum_31_60d	сумма показателя «поисковые запросы» с 31-го по 60-й день до опорной даты	$S_{\text{queries}}(W_{31:60})$
searches_sum_61_90d	сумма показателя «поисковые запросы» с 61-го по 90-й день до опорной даты	$S_{\text{queries}}(W_{61:90})$
searches_sum_7d	сумма показателя «поисковые запросы» за последние 7 дней	$S_{\text{queries}}(W_7)$
searches_sum_8_30d	сумма показателя «поисковые запросы» с 8-го по 30-й день до опорной даты	$S_{\text{queries}}(W_{8:30})$
searches_sum_90d	сумма показателя «поисковые запросы» за последние 90 дней	$S_{\text{queries}}(W_{90})$
searches_sum_91_180d	сумма показателя «поисковые запросы» с 91-го по 180-й день до опорной даты	$S_{\text{queries}}(W_{91:180})$
to_cart_active_days_30d	число строк с положительным значением «товары, добавленные в корзину» за последние 30 дней	$N^+_{\text{cart}}(W_{30})$
to_cart_active_days_7d	число строк с положительным значением «товары, добавленные в корзину» за последние 7 дней	$N^+_{\text{cart}}(W_7)$
to_cart_active_days_90d	число строк с положительным значением «товары, добавленные в корзину» за последние 90 дней	$N^+_{\text{cart}}(W_{90})$
to_cart_daily_trend_31_60_vs_61_90	разность среднесуточного показателя «товары, добавленные в корзину» между периодами с 31-го по 60-й день до опорной даты и с 61-го по 90-й день до опорной даты	$S_{\text{cart}}(W_{31:60})/30 - S_{\text{cart}}(W_{61:90})/30$
to_cart_daily_trend_7_vs_8_30	разность среднесуточного показателя «товары, добавленные в корзину» между периодами за последние 7 дней и с 8-го по 30-й день до опорной даты	$S_{\text{cart}}(W_7)/7 - S_{\text{cart}}(W_{8:30})/23$
to_cart_daily_trend_8_30_vs_31_60	разность среднесуточного показателя «товары, добавленные в корзину» между периодами с 8-го по 30-й день до опорной даты и с 31-го по 60-й день до опорной даты	$S_{\text{cart}}(W_{8:30})/23 - S_{\text{cart}}(W_{31:60})/30$
to_cart_max_30d	максимальное значение «товары, добавленные в корзину» за последние 30 дней	$\max_{d \in W_{30}} x_d$

Продолжение на следующей странице

Продолжение таблицы 12

Название в коде	Смысл на русском	Расчёт
to_cart_max_7d	максимальное значение «товары, добавленные в корзину» за последние 7 дней	$\max_{d \in W_7} x_d$
to_cart_max_90d	максимальное значение «товары, добавленные в корзину» за последние 90 дней	$\max_{d \in W_{90}} x_d$
to_cart_mean_active_30d	среднее значение «товары, добавленные в корзину» по наблюдаемым строкам за последние 30 дней	$\text{mean}_{d \in W_{30} \cap \text{obs}} x_d$
to_cart_mean_active_7d	среднее значение «товары, добавленные в корзину» по наблюдаемым строкам за последние 7 дней	$\text{mean}_{d \in W_7 \cap \text{obs}} x_d$
to_cart_mean_active_90d	среднее значение «товары, добавленные в корзину» по наблюдаемым строкам за последние 90 дней	$\text{mean}_{d \in W_{90} \cap \text{obs}} x_d$
to_cart_sum_30d	сумма показателя «товары, добавленные в корзину» за последние 30 дней	$S_{\text{cart}}(W_{30})$
to_cart_sum_31_60d	сумма показателя «товары, добавленные в корзину» с 31-го по 60-й день до опорной даты	$S_{\text{cart}}(W_{31:60})$
to_cart_sum_61_90d	сумма показателя «товары, добавленные в корзину» с 61-го по 90-й день до опорной даты	$S_{\text{cart}}(W_{61:90})$
to_cart_sum_7d	сумма показателя «товары, добавленные в корзину» за последние 7 дней	$S_{\text{cart}}(W_7)$
to_cart_sum_8_30d	сумма показателя «товары, добавленные в корзину» с 8-го по 30-й день до опорной даты	$S_{\text{cart}}(W_{8:30})$
to_cart_sum_90d	сумма показателя «товары, добавленные в корзину» за последние 90 дней	$S_{\text{cart}}(W_{90})$
to_cart_sum_91_180d	сумма показателя «товары, добавленные в корзину» с 91-го по 180-й день до опорной даты	$S_{\text{cart}}(W_{91:180})$
to_ord_active_days_30d	число строк с положительным значением «заказанные товары» за последние 30 дней	$N^+_{\text{ord}}(W_{30})$
to_ord_active_days_31_60d	число строк с положительным значением «заказанные товары» с 31-го по 60-й день до опорной даты	$N^+_{\text{ord}}(W_{31:60})$
to_ord_active_days_61_90d	число строк с положительным значением «заказанные товары» с 61-го по 90-й день до опорной даты	$N^+_{\text{ord}}(W_{61:90})$
to_ord_active_days_7d	число строк с положительным значением «заказанные товары» за последние 7 дней	$N^+_{\text{ord}}(W_7)$
to_ord_active_days_8_30d	число строк с положительным значением «заказанные товары» с 8-го по 30-й день до опорной даты	$N^+_{\text{ord}}(W_{8:30})$
to_ord_active_days_90d	число строк с положительным значением «заказанные товары» за последние 90 дней	$N^+_{\text{ord}}(W_{90})$
to_ord_active_days_91_180d	число строк с положительным значением «заказанные товары» с 91-го по 180-й день до опорной даты	$N^+_{\text{ord}}(W_{91:180})$
to_ord_daily_trend_31_60_vs_61_90	разность среднесуточного показателя «заказанные товары» между периодами с 31-го по 60-й день до опорной даты и с 61-го по 90-й день до опорной даты	$S_{\text{ord}}(W_{31:60})/30 - S_{\text{ord}}(W_{61:90})/30$
to_ord_daily_trend_7_vs_8_30	разность среднесуточного показателя «заказанные товары» между периодами за последние 7 дней и с 8-го по 30-й день до опорной даты	$S_{\text{ord}}(W_7)/7 - S_{\text{ord}}(W_{8:30})/23$

Продолжение на следующей странице

Продолжение таблицы 12

Название в коде	Смысл на русском	Расчёт
to_ord_daily_trend_8_30_vs_31_60	разность среднесуточного показателя «заказанные товары» между периодами с 8-го по 30-й день до опорной даты и с 31-го по 60-й день до опорной даты	$S_{ord}(W_{8:30})/23 - S_{ord}(W_{31:60})/30$
to_ord_max_30d	максимальное значение «заказанные товары» за последние 30 дней	$\max_{d \in W_{30}} x_d$
to_ord_max_7d	максимальное значение «заказанные товары» за последние 7 дней	$\max_{d \in W_7} x_d$
to_ord_max_90d	максимальное значение «заказанные товары» за последние 90 дней	$\max_{d \in W_{90}} x_d$
to_ord_mean_active_30d	среднее значение «заказанные товары» по наблюдаемым строкам за последние 30 дней	$\text{mean}_{d \in W_{30} \cap \text{obs}} x_d$
to_ord_mean_active_7d	среднее значение «заказанные товары» по наблюдаемым строкам за последние 7 дней	$\text{mean}_{d \in W_7 \cap \text{obs}} x_d$
to_ord_mean_active_90d	среднее значение «заказанные товары» по наблюдаемым строкам за последние 90 дней	$\text{mean}_{d \in W_{90} \cap \text{obs}} x_d$
to_ord_mean_positive_31_60d	среднее положительное значение «заказанные товары» с 31-го по 60-й день до опорной даты	$S_{ord}(W_{31:60})/N^+_{ord}(W_{31:60})$
to_ord_mean_positive_61_90d	среднее положительное значение «заказанные товары» с 61-го по 90-й день до опорной даты	$S_{ord}(W_{61:90})/N^+_{ord}(W_{61:90})$
to_ord_mean_positive_8_30d	среднее положительное значение «заказанные товары» с 8-го по 30-й день до опорной даты	$S_{ord}(W_{8:30})/N^+_{ord}(W_{8:30})$
to_ord_mean_positive_91_180d	среднее положительное значение «заказанные товары» с 91-го по 180-й день до опорной даты	$S_{ord}(W_{91:180})/N^+_{ord}(W_{91:180})$
to_ord_sum_30d	сумма показателя «заказанные товары» за последние 30 дней	$S_{ord}(W_{30})$
to_ord_sum_31_60d	сумма показателя «заказанные товары» с 31-го по 60-й день до опорной даты	$S_{ord}(W_{31:60})$
to_ord_sum_61_90d	сумма показателя «заказанные товары» с 61-го по 90-й день до опорной даты	$S_{ord}(W_{61:90})$
to_ord_sum_7d	сумма показателя «заказанные товары» за последние 7 дней	$S_{ord}(W_7)$
to_ord_sum_8_30d	сумма показателя «заказанные товары» с 8-го по 30-й день до опорной даты	$S_{ord}(W_{8:30})$
to_ord_sum_90d	сумма показателя «заказанные товары» за последние 90 дней	$S_{ord}(W_{90})$
to_ord_sum_91_180d	сумма показателя «заказанные товары» с 91-го по 180-й день до опорной даты	$S_{ord}(W_{91:180})$

Описание таблицы. В таблице перечислены все 216 признаков группы, которые вошли в итоговую денежную модель. Расчёт выполняется в файле `src/features.py`. Формулы используют обозначения, введённые перед таблицами.

Таблица 13: Признаки аналогичного календарного периода прошлого года

Название в коде	Смысл на русском	Расчёт
ly_pre_14d_gmv	прошлогондня сумма «GMV» за 14 дней до соответствующей опорной даты	$S_{gmv}(W_{pre,14}^{LY})$
ly_pre_14d_searches	прошлогондня сумма «поисковые запросы» за 14 дней до соответствующей опорной даты	$S_{queries}(W_{pre,14}^{LY})$
ly_pre_14d_to_ord	прошлогондня сумма «заказанные товары» за 14 дней до соответствующей опорной даты	$S_{ord}(W_{pre,14}^{LY})$
ly_pre_7d_gmv	прошлогондня сумма «GMV» за 7 дней до соответствующей опорной даты	$S_{gmv}(W_{pre,7}^{LY})$
ly_pre_7d_searches	прошлогондня сумма «поисковые запросы» за 7 дней до соответствующей опорной даты	$S_{queries}(W_{pre,7}^{LY})$
ly_pre_7d_to_ord	прошлогондня сумма «заказанные товары» за 7 дней до соответствующей опорной даты	$S_{ord}(W_{pre,7}^{LY})$
ly_profile_active_span_days	длина отрезка между первым и последним днём с GMV включительно	$d_{last} - d_{first} + 1$
ly_profile_avg_order_value	GMV на заказанный товар в прошлогондном периоде	$V/(Q + 1)$
ly_profile_day_0_gmv	GMV первого дня прошлогондного периода	v_0
ly_profile_days_20_24_gmv	GMV дней с номерами от 20 до 24	$\sum_{d=20}^{24} v_d$
ly_profile_days_7_11_gmv	GMV дней с номерами от 7 до 11	$\sum_{d=7}^{11} v_d$
ly_profile_first_gmv_offset	номер первого дня с GMV внутри периода, от 0 до 29	$\min(d : v_d > 0)$
ly_profile_global_cosine	косинусное сходство личного и общего дневных профилей	$\sum_d v_d G_d / [\sqrt{\sum_d v_d^2 \sum_d G_d^2} + 10^{-6}]$
ly_profile_global_cosine_numerator	числитель косинусного сходства с общим дневным профилем	$\sum_d v_d G_d$
ly_profile_global_intensity	средняя общая доля дня, взвешенная GMV пользователя и умноженная на 30	$30 \sum_d v_d w_d / V$
ly_profile_global_weighted_gmv	GMV, взвешенный общей долей дня в обороте	$\sum_d v_d w_d$
ly_profile_gmv	суммарный GMV прошлогондного периода	$\sum_{d \in HLY} v_d$
ly_profile_gmv_cv	коэффициент вариации дневного GMV	$sd(v)/(\bar{v} + 10^{-6})$
ly_profile_gmv_days	число дней с положительным GMV	$\sum_d \mathbf{1}(v_d > 0)$
ly_profile_gmv_entropy_normalized	нормированная энтропия распределения GMV по 30 дням	$[\log V - \sum_d v_d \log v_d / V] / \log 30$
ly_profile_gmv_hhi	концентрация GMV по дням	$\sum_d v_d^2 / [(\sum_d v_d)^2 + 10^{-6}]$
ly_profile_gmv_max_day	максимальный дневной GMV прошлогондного периода	$\max_d v_d$
ly_profile_gmv_mean_day	средний дневной GMV с учётом нулевых дней	$\sum_d v_d / 30$
ly_profile_gmv_median_positive_day	медианный GMV среди дней с положительным GMV	$\text{median}(v_d \mid v_d > 0)$
ly_profile_gmv_sq_sum	сумма квадратов дневного GMV прошлогондного периода	$\sum_{d \in HLY} v_d^2$
ly_profile_gmv_std_day	стандартное отклонение дневного GMV с учётом нулевых дней	$\sqrt{\sum_d v_d^2 / 30 - \bar{v}^2}$
ly_profile_gmv_top3_sum	сумма GMV трёх крупнейших дней	$\sum_{d \in Top3(v)} v_d$
ly_profile_gmv_xlogx_sum	сумма произведений дневного GMV на его логарифм	$\sum_{v_d > 0} v_d \log v_d$

Продолжение на следующей странице

Продолжение таблицы 13

Название в коде	Смысл на русском	Расчёт
ly_profile_last_gmv_offset	номер последнего дня с GMV внутри периода, от 0 до 29	$\max(d : v_d > 0)$
ly_profile_mean_gap_days	средняя равномерная оценка паузы между днями с GMV	$(d_{last} - d_{first}) / (N_{gmv}^+ - 1)$
ly_profile_observed_days	число наблюдаемых строк в прошлогоднем 30-дневном периоде	$N_{obs}(H^{LY})$
ly_profile_order_days	число дней с заказанными товарами	$\sum_d \mathbf{1}(q_d > 0)$
ly_profile_orders	число заказанных товаров за прошлогодний период	$\sum_d q_d$
ly_profile_peak_gmv_offset	номер дня с максимальным GMV внутри периода	$\arg \max_d v_d$
ly_profile_reliability_segment	категория наполненности профиля: 0, 1, 2 или 3	$0 (V = 0), 1 (N \leq 1), 2 (N \leq 3), 3 (N > 3)$
ly_profile_search_days	число дней с поисковыми запросами	$\sum_d \mathbf{1}(s_d > 0)$
ly_profile_search_to_order	заказанные товары на поисковый запрос в прошлогоднем периоде	$Q / (S + 1)$
ly_profile_searches	число поисковых запросов за прошлогодний период	$\sum_d s_d$
ly_profile_segment_1_gmv	сумма «GMV» в части 1 прошлогоднего периода	$S_{gmv}(H_{0:6}^{LY})$
ly_profile_segment_1_gmv_share	доля части 1 в GMV прошлогоднего периода	$V_1 / (V + 10^{-6})$
ly_profile_segment_1_searches	сумма «поисковые запросы» в части 1 прошлогоднего периода	$S_{queries}(H_{0:6}^{LY})$
ly_profile_segment_1_to_ord	сумма «заказанные товары» в части 1 прошлогоднего периода	$S_{ord}(H_{0:6}^{LY})$
ly_profile_segment_2_gmv	сумма «GMV» в части 2 прошлогоднего периода	$S_{gmv}(H_{7:14}^{LY})$
ly_profile_segment_2_gmv_share	доля части 2 в GMV прошлогоднего периода	$V_2 / (V + 10^{-6})$
ly_profile_segment_2_searches	сумма «поисковые запросы» в части 2 прошлогоднего периода	$S_{queries}(H_{7:14}^{LY})$
ly_profile_segment_2_to_ord	сумма «заказанные товары» в части 2 прошлогоднего периода	$S_{ord}(H_{7:14}^{LY})$
ly_profile_segment_3_gmv	сумма «GMV» в части 3 прошлогоднего периода	$S_{gmv}(H_{15:22}^{LY})$
ly_profile_segment_3_gmv_share	доля части 3 в GMV прошлогоднего периода	$V_3 / (V + 10^{-6})$
ly_profile_segment_3_searches	сумма «поисковые запросы» в части 3 прошлогоднего периода	$S_{queries}(H_{15:22}^{LY})$
ly_profile_segment_3_to_ord	сумма «заказанные товары» в части 3 прошлогоднего периода	$S_{ord}(H_{15:22}^{LY})$
ly_profile_segment_4_gmv	сумма «GMV» в части 4 прошлогоднего периода	$S_{gmv}(H_{23:29}^{LY})$
ly_profile_segment_4_gmv_share	доля части 4 в GMV прошлогоднего периода	$V_4 / (V + 10^{-6})$
ly_profile_segment_4_searches	сумма «поисковые запросы» в части 4 прошлогоднего периода	$S_{queries}(H_{23:29}^{LY})$
ly_profile_segment_4_to_ord	сумма «заказанные товары» в части 4 прошлогоднего периода	$S_{ord}(H_{23:29}^{LY})$
ly_profile_top1_gmv_share	доля крупнейшего дня в GMV периода	$\max(v_d) / (V + 10^{-6})$

Продолжение на следующей странице

Продолжение таблицы 13

Название в коде	Смысл на русском	Расчёт
ly_profile_top3_gmv_share	доля трёх крупнейших дней в GMV периода	$Top3(V)/(V + 10^{-6})$
ly_profile_weekend_gmv	GMV суббот и воскресений прошлогоднего периода	$\sum_{d \in weekend} v_d$
ly_profile_weekend_gmv_share	доля суббот и воскресений в GMV периода	$V_{weekend}/(V + 10^{-6})$

Описание таблицы. В таблице перечислены все 58 признаков группы, которые вошли в итоговую денежную модель. Расчёт выполняется в файле `src/seasonality.py`. Формулы используют обозначения, введённые перед таблицами.

Таблица 14: Признаки годовой истории

Название в коде	Смысл на русском	Расчёт
annual_profile_available	признак наличия рассчитанного годового профиля	1
available_history_days_365d	фактически доступная длина истории, не более 365 дней	L
avg_order_value_365d	GMV на заказанный товар за годовую историю	$S_{gmv}(W_{365})/[S_{ord}(W_{365}) + 1]$
cat_sum_181_365d	сумма «использование Каталога» с 181-го по 365-й день до опорной даты	$S_{cat}(W_{181:365})$
cat_sum_365d	сумма «использование Каталога» за доступную историю до 365 дней	$S_{cat}(W_{365})$
cat_to_cart_sum_181_365d	сумма «товары в корзине после Каталога» с 181-го по 365-й день до опорной даты	$S_{cart,c}(W_{181:365})$
cat_to_cart_sum_365d	сумма «товары в корзине после Каталога» за доступную историю до 365 дней	$S_{cart,c}(W_{365})$
cat_to_ord_sum_181_365d	сумма «заказанные товары после Каталога» с 181-го по 365-й день до опорной даты	$S_{ord,c}(W_{181:365})$
cat_to_ord_sum_365d	сумма «заказанные товары после Каталога» за доступную историю до 365 дней	$S_{ord,c}(W_{365})$
days_since_last_gmv_365d	число дней с последнего положительного GMV	$t - \max(d : v_d > 0)$
days_since_last_order_365d	число дней с последнего дня с заказом	$t - \max(d : q_d > 0)$
gmv_active_days_365d	число строк с положительным значением «GMV» за годовую историю	$N^+_{gmv}(W_{365})$
gmv_blocks_max_log1p	максимум логарифмов сумм 12 блоков для показателя «GMV»	$\max_k b_k$
gmv_blocks_mean_log1p	среднее логарифмов сумм 12 блоков для показателя «GMV»	$\text{mean}_k b_k$
gmv_blocks_median_log1p	медиана логарифмов сумм 12 блоков для показателя «GMV»	$\text{median}_k b_k$
gmv_blocks_positive_share	доля из 12 блоков с положительной суммой для показателя «GMV»	$12^{-1} \sum_{k=0}^{11} \mathbf{1}(B_k > 0)$
gmv_blocks_recent3_minus_older9_log1p	разность среднего трёх свежих и девяти более старых блоков для показателя «GMV»	$\bar{b}_{0:2} - \bar{b}_{3:11}$
gmv_blocks_recent3_minus_previous3_log1p	разность среднего трёх свежих и трёх предыдущих блоков для показателя «GMV»	$\bar{b}_{0:2} - \bar{b}_{3:5}$
gmv_blocks_recent6_minus_older6_log1p	разность среднего шести свежих и шести старых блоков для показателя «GMV»	$\bar{b}_{0:5} - \bar{b}_{6:11}$
gmv_blocks_slope_log1p	наклон прямой по логарифмам блоков, где 0 означает самый свежий блок для показателя «GMV»	$[12 \sum k b_k - 66 \sum b_k]/1716$
gmv_blocks_std_log1p	стандартное отклонение логарифмов сумм 12 блоков для показателя «GMV»	$sd_k(b_k)$
gmv_cat_sum_181_365d	сумма «GMV из Каталога» с 181-го по 365-й день до опорной даты	$S_{gmv,c}(W_{181:365})$
gmv_cat_sum_365d	сумма «GMV из Каталога» за доступную историю до 365 дней	$S_{gmv,c}(W_{365})$
gmv_recent90_share_365d	доля последних 90 дней в годовом GMV	$S_{gmv}(W_{90})/[S_{gmv}(W_{365}) + 1]$
gmv_search_sum_181_365d	сумма «GMV из Поиска» с 181-го по 365-й день до опорной даты	$S_{gmv,s}(W_{181:365})$
gmv_search_sum_365d	сумма «GMV из Поиска» за доступную историю до 365 дней	$S_{gmv,s}(W_{365})$

Продолжение на следующей странице

Продолжение таблицы 14

Название в коде	Смысл на русском	Расчёт
gmv_sum_181_365d	сумма «GMV» с 181-го по 365-й день до опорной даты	$S_{gmv}(W_{181:365})$
gmv_sum_365d	сумма «GMV» за доступную историю до 365 дней	$S_{gmv}(W_{365})$
observed_sparse_rows_365d	число наблюдаемых строк за доступную годовую историю	$N_{obs}(W_{365})$
order_active_span_days_365d	расстояние в днях между первым и последним днём с заказом	$d_{last}^{ord} - d_{first}^{ord}$
order_gap_mean_days_365d	средняя пауза между последовательными днями с заказами	$\text{mean}(g_i)$
order_gap_std_days_365d	стандартное отклонение пауз между днями с заказами	$sd(g_i)$
orders_recent90_share_365d	доля последних 90 дней в годовом числе заказанных товаров	$S_{ord}(W_{90})/[S_{ord}(W_{365}) + 1]$
search_gmv_share_365d	доля GMV из Поиска за годовую историю	$S_{gmv,s}(W_{365})/[S_{gmv}(W_{365}) + 1]$
search_sum_181_365d	сумма «использование Поиска» с 181-го по 365-й день до опорной даты	$S_{search}(W_{181:365})$
search_sum_365d	сумма «использование Поиска» за доступную историю до 365 дней	$S_{search}(W_{365})$
search_to_cart_sum_181_365d	сумма «товары в корзине после Поиска» с 181-го по 365-й день до опорной даты	$S_{cart,s}(W_{181:365})$
search_to_cart_sum_365d	сумма «товары в корзине после Поиска» за доступную историю до 365 дней	$S_{cart,s}(W_{365})$
search_to_ord_sum_181_365d	сумма «заказанные товары после Поиска» с 181-го по 365-й день до опорной даты	$S_{ord,s}(W_{181:365})$
search_to_ord_sum_365d	сумма «заказанные товары после Поиска» за доступную историю до 365 дней	$S_{ord,s}(W_{365})$
searches_active_days_365d	число строк с положительным значением «поисковые запросы» за годовую историю	$N_{queries}^{+}(W_{365})$
searches_blocks_max_log1p	максимум логарифмов сумм 12 блоков для показателя «поисковые запросы»	$\max_k b_k$
searches_blocks_mean_log1p	среднее логарифмов сумм 12 блоков для показателя «поисковые запросы»	$\text{mean}_k b_k$
searches_blocks_median_log1p	медиана логарифмов сумм 12 блоков для показателя «поисковые запросы»	$\text{median}_k b_k$
searches_blocks_positive_share	доля из 12 блоков с положительной суммой для показателя «поисковые запросы»	$12^{-1} \sum_{k=0}^{11} \mathbf{1}(B_k > 0)$
searches_blocks_recent3_minus_older9_log1p	разность среднего трёх свежих и девяти более старых блоков для показателя «поисковые запросы»	$\bar{b}_{0:2} - \bar{b}_{3:11}$
searches_blocks_recent3_minus_previous3_log1p	разность среднего трёх свежих и трёх предыдущих блоков для показателя «поисковые запросы»	$\bar{b}_{0:2} - \bar{b}_{3:5}$
searches_blocks_recent6_minus_older6_log1p	разность среднего шести свежих и шести старых блоков для показателя «поисковые запросы»	$\bar{b}_{0:5} - \bar{b}_{6:11}$
searches_blocks_slope_log1p	наклон прямой по логарифмам блоков, где 0 означает самый свежий блок для показателя «поисковые запросы»	$[12 \sum k b_k - 66 \sum b_k]/1716$
searches_blocks_std_log1p	стандартное отклонение логарифмов сумм 12 блоков для показателя «поисковые запросы»	$sd_k(b_k)$
searches_sum_181_365d	сумма «поисковые запросы» с 181-го по 365-й день до опорной даты	$S_{queries}(W_{181:365})$

Продолжение на следующей странице

Продолжение таблицы 14

Название в коде	Смысл на русском	Расчёт
searches_sum_365d	сумма «поисковые запросы» за доступную историю до 365 дней	$S_{queries}(W_{365})$
to_cart_active_days_365d	число строк с положительным значением «товары, добавленные в корзину» за годовую историю	$N^+_{cart}(W_{365})$
to_cart_sum_181_365d	сумма «товары, добавленные в корзину» с 181-го по 365-й день до опорной даты	$S_{cart}(W_{181:365})$
to_cart_sum_365d	сумма «товары, добавленные в корзину» за доступную историю до 365 дней	$S_{cart}(W_{365})$
to_ord_active_days_365d	число строк с положительным значением «заказанные товары» за годовую историю	$N^+_{ord}(W_{365})$
to_ord_blocks_max_log1p	максимум логарифмов сумм 12 блоков для показателя «заказанные товары»	$\max_k b_k$
to_ord_blocks_mean_log1p	среднее логарифмов сумм 12 блоков для показателя «заказанные товары»	$\text{mean}_k b_k$
to_ord_blocks_median_log1p	медиана логарифмов сумм 12 блоков для показателя «заказанные товары»	$\text{median}_k b_k$
to_ord_blocks_positive_share	доля из 12 блоков с положительной суммой для показателя «заказанные товары»	$12^{-1} \sum_{k=0}^{11} \mathbf{1}(B_k > 0)$
to_ord_blocks_recent3_minus_older9_log1p	разность среднего трёх свежих и девяти более старых блоков для показателя «заказанные товары»	$\bar{b}_{0:2} - \bar{b}_{3:11}$
to_ord_blocks_recent3_minus_previous3_log1p	разность среднего трёх свежих и трёх предыдущих блоков для показателя «заказанные товары»	$\bar{b}_{0:2} - \bar{b}_{3:5}$
to_ord_blocks_recent6_minus_older6_log1p	разность среднего шести свежих и шести старых блоков для показателя «заказанные товары»	$\bar{b}_{0:5} - \bar{b}_{6:11}$
to_ord_blocks_slope_log1p	наклон прямой по логарифмам блоков, где 0 означает самый свежий блок для показателя «заказанные товары»	$[12 \sum k b_k - 66 \sum b_k] / 1716$
to_ord_blocks_std_log1p	стандартное отклонение логарифмов сумм 12 блоков для показателя «заказанные товары»	$sd_k(b_k)$
to_ord_sum_181_365d	сумма «заказанные товары» с 181-го по 365-й день до опорной даты	$S_{ord}(W_{181:365})$
to_ord_sum_365d	сумма «заказанные товары» за доступную историю до 365 дней	$S_{ord}(W_{365})$

Описание таблицы. В таблице перечислены все 67 признаков группы, которые вошли в итоговую денежную модель. Расчёт выполняется в файле `src/annual_features.py`. Формулы используют обозначения, введённые перед таблицами.

Таблица 15: Признаки периодичности заказов

Название в коде	Смысл на русском	Расчёт
cadence_available_history_days	фактически доступная длина истории	L
order_cadence_active_days	число разных дней с заказами	m
order_cadence_active_span_days	расстояние между первым и последним днём с заказом	$d_m - d_1$
order_cadence_days_until_expected	остаток до типичного следующего цикла, отрицательный при опоздании	$\tilde{g} - r$
order_cadence_dominant_weekday	номер дня недели с наибольшим числом заказанных товаров, от 0 до 6	$\arg \max_k p_k$
order_cadence_gap_count	число рассчитанных пауз между днями с заказами	$m - 1$
order_cadence_gap_cv	коэффициент вариации пауз	$sd(g)/\max(\tilde{g}, 1)$
order_cadence_gap_iqr	межквартильный размах пауз	$Q_{0.75}(g) - Q_{0.25}(g)$
order_cadence_gap_last	последняя пауза между днями с заказами	g_{m-1}
order_cadence_gap_max	максимальная пауза	$\max_i g_i$
order_cadence_gap_mean	средняя пауза между днями с заказами	$\tilde{g}$
order_cadence_gap_median	медианная пауза между днями с заказами	$\text{median}(g_i)$
order_cadence_gap_min	минимальная пауза	$\min_i g_i$
order_cadence_gap_previous	предпоследняя пауза между днями с заказами	g_{m-2}
order_cadence_gap_q25	первая четверть распределения пауз	$Q_{0.25}(g)$
order_cadence_gap_q75	третья четверть распределения пауз	$Q_{0.75}(g)$
order_cadence_gap_recent3_mean	среднее трёх последних пауз	$\text{mean}(g_{m-3:m-1})$
order_cadence_gap_recent5_mean	среднее пяти последних пауз	$\text{mean}(g_{m-5:m-1})$
order_cadence_gap_std	стандартное отклонение пауз	$sd(g_i)$
order_cadence_gap_third	третья с конца пауза между днями с заказами	g_{m-3}
order_cadence_missed_cycles	целое число медианных циклов, прошедших после последнего заказа, с ограничением 20	$\text{clip}(\lfloor r/\max(\tilde{g}, 1) \rfloor, 0, 20)$
order_cadence_multiple_order_day_share	доля дней, когда было заказано больше одного товара	$m^{-1} \sum_i 1(q_i > 1)$
order_cadence_orders_on_last_active_day	число заказанных товаров в последний день с заказом	q_m
order_cadence_orders_per_active_day_max	максимальное число заказанных товаров за один день	$\max_i q_i$
order_cadence_orders_per_active_day_mean	среднее число заказанных товаров в день с заказом	$\bar{q}$
order_cadence_orders_per_active_day_std	стандартное отклонение числа товаров в день с заказом	$sd(q_i)$
order_cadence_recency_days	число дней с последнего дня с заказом	$r = t - d_m$
order_cadence_recency_minus_median	разность давности и медианной паузы	$r - \tilde{g}$
order_cadence_recency_over_median	давность последнего заказа относительно медианной паузы	$r/\max(\tilde{g}, 1)$

Продолжение на следующей странице

Продолжение таблицы 15

Название в коде	Смысл на русском	Расчёт
order_cadence_recent3_vs_all	отношение среднего трёх последних пауз к общему среднему	$\bar{g}_{last3} / \max(\bar{g}, 1)$
order_cadence_regularity_score	оценка регулярности пауз	$1 / [1 + sd(g) / \max(\bar{g}, 1)]$
order_cadence_total_orders	суммарное число заказанных товаров по дням с заказами	$\sum_{i=1}^m q_i$
order_cadence_weekday_entropy	нормированная энтропия распределения заказанных товаров по дням недели	$-\sum_{k=1}^7 p_k \log p_k / \log 7$
order_cadence_weekday_max_share	максимальная доля одного дня недели в заказанных товарах	$\max_k p_k$

Описание таблицы. В таблице перечислены все 34 признака группы, которые вошли в итоговую денежную модель. Расчёт выполняется в файле `src/cadence_features.py`. Формулы используют обозначения, введённые перед таблицами.

Таблица 16: Признаки денежного поведения

Название в коде	Смысл на русском	Расчёт
money_aov_day_cv	коэффициент вариации стоимости товара по покупательским дням	$sd(a)/\max(\bar{a}, 1)$
money_aov_day_max	максимальная средняя стоимость товара одного покупательского дня	$\max_j a_j$
money_aov_day_mean	средняя стоимость заказанного товара по покупательским дням	$\bar{a}$
money_aov_day_median	медианная стоимость товара по покупательским дням	$\text{median}(a_j)$
money_aov_day_q25	первая четверть стоимости товара по покупательским дням	$Q_{0.25}(a)$
money_aov_day_q75	третья четверть стоимости товара по покупательским дням	$Q_{0.75}(a)$
money_aov_day_std	стандартное отклонение стоимости товара по покупательским дням	$sd(a_j)$
money_decayed_gmv_14d	затухающая сумма GMV с масштабом 14 дней	$\sum_j v_j \exp(-age_j/14)$
money_decayed_gmv_30d	затухающая сумма GMV с масштабом 30 дней	$\sum_j v_j \exp(-age_j/30)$
money_decayed_gmv_60d	затухающая сумма GMV с масштабом 60 дней	$\sum_j v_j \exp(-age_j/60)$
money_decayed_gmv_7d	затухающая сумма GMV с масштабом 7 дней	$\sum_j v_j \exp(-age_j/7)$
money_decayed_gmv_90d	затухающая сумма GMV с масштабом 90 дней	$\sum_j v_j \exp(-age_j/90)$
money_decayed_orders_14d	затухающая сумма заказанных товаров с масштабом 14 дней	$\sum_j q_j \exp(-age_j/14)$
money_decayed_orders_30d	затухающая сумма заказанных товаров с масштабом 30 дней	$\sum_j q_j \exp(-age_j/30)$
money_decayed_orders_60d	затухающая сумма заказанных товаров с масштабом 60 дней	$\sum_j q_j \exp(-age_j/60)$
money_decayed_orders_7d	затухающая сумма заказанных товаров с масштабом 7 дней	$\sum_j q_j \exp(-age_j/7)$
money_decayed_orders_90d	затухающая сумма заказанных товаров с масштабом 90 дней	$\sum_j q_j \exp(-age_j/90)$
money_expected_cycles_30d	ожидаемое число покупательских циклов за 30 дней по медианной паузе	$1_{m \geq 2} \text{clip}[30/\max(\bar{g}, 1), 0, 30]$
money_expected_gmv_by_cycle_30d	ожидаемый GMV по циклу и среднему последних пяти покупательских дней	$C_{30} \bar{v}_{last5}$
money_expected_gmv_by_rate_30d	ожидаемый GMV по среднесуточному темпу доступной истории	$30 \sum_j v_j / L$
money_expected_orders_by_rate_30d	ожидаемое число покупательских дней по среднесуточному темпу истории	$30m/L$
money_gmv_day_cv	коэффициент вариации GMV покупательских дней	$sd(v)/\max(\bar{v}, 1)$
money_gmv_day_max	максимальный GMV покупательского дня	$\max_j v_j$
money_gmv_day_mean	средний GMV покупательского дня	$\bar{v}$
money_gmv_day_median	медианный GMV покупательского дня	$\text{median}(v_j)$
money_gmv_day_q25	первая четверть GMV покупательских дней	$Q_{0.25}(v)$
money_gmv_day_q75	третья четверть GMV покупательских дней	$Q_{0.75}(v)$
money_gmv_day_std	стандартное отклонение GMV покупательского дня	$sd(v_j)$
money_last3_gmv_share	доля трёх последних покупательских дней в GMV всей истории	$\sum_{last3} v / \max(\sum_j v_j, 1)$
money_last3_vs_all_gmv_log	логарифмическое изменение среднего GMV последних трёх дней относительно всей истории	$\log(1 + \bar{v}_{last3}) - \log(1 + \bar{v})$

Продолжение на следующей странице

Продолжение таблицы 16

Название в коде	Смысл на русском	Расчёт
money_last3_vs_previous3_aov_log	логарифмическое изменение стоимости товара последних трёх дней относительно предыдущих трёх	$\log(1 + \bar{a}_{last3}) - \log(1 + \bar{a}_{prev3})$
money_last3_vs_previous3_gmv_log	логарифмическое изменение суммы GMV последних трёх дней относительно предыдущих трёх	$\log(1 + \sum_{last3} v) - \log(1 + \sum_{prev3} v)$
money_last_aov	стоимость товара в последнем покупательском дне	a_m
money_last_gmv	GMV последнего покупательского дня	v_m
money_last_orders	число заказанных товаров в последнем покупательском дне	q_m
money_previous_aov	стоимость товара в предпоследнем покупательском дне	a_{m-1}
money_previous_gmv	GMV предпоследнего покупательского дня	v_{m-1}
money_previous_orders	число заказанных товаров в предпоследнем покупательском дне	q_{m-1}
money_recency_adjusted_gmv_30d	циклическая оценка GMV с поправкой на давность последней покупки	$C_{30} \bar{v}_{last5} \exp[-r / \max(\tilde{g}, 1)]$
money_recent10_aov_mean	среднее значение «стоимость заказанного товара» по 10 последним покупательским дням	$\text{mean}(a_{last10})$
money_recent10_gmv_mean	среднее значение «GMV» по 10 последним покупательским дням	$\text{mean}(v_{last10})$
money_recent3_aov_mean	среднее значение «стоимость заказанного товара» по 3 последним покупательским дням	$\text{mean}(a_{last3})$
money_recent3_gmv_mean	среднее значение «GMV» по 3 последним покупательским дням	$\text{mean}(v_{last3})$
money_recent3_orders_mean	среднее значение «число заказанных товаров» по 3 последним покупательским дням	$\text{mean}(q_{last3})$
money_recent5_aov_mean	среднее значение «стоимость заказанного товара» по 5 последним покупательским дням	$\text{mean}(a_{last5})$
money_recent5_cat_gmv_share	доля Каталога в GMV из Поиска и Каталога за пять последних покупательских дней	$V_{last5}^c / \max(V_{last5}^s + V_{last5}^c, 1)$
money_recent5_gmv_mean	среднее значение «GMV» по 5 последним покупательским дням	$\text{mean}(v_{last5})$
money_recent5_orders_mean	среднее значение «число заказанных товаров» по 5 последним покупательским дням	$\text{mean}(q_{last5})$
money_recent5_search_gmv_share	доля Поиска в GMV из Поиска и Каталога за пять последних покупательских дней	$V_{last5}^s / \max(V_{last5}^s + V_{last5}^c, 1)$
money_recent5_search_share_minus_all	изменение доли GMV из Поиска в последних пяти покупательских днях относительно всей истории	$share_{last5}^s - V^s / \max(V, 1)$
money_third_aov	стоимость товара в третьем с конца покупательском дне	a_{m-2}
money_third_gmv	GMV третьего с конца покупательского дня	v_{m-2}
money_third_orders	число заказанных товаров в третьем с конца покупательском дне	q_{m-2}

Описание таблицы. В таблице перечислены все 53 признака группы, которые вошли в итоговую денежную модель. Расчёт выполняется в файле `src/monetary_cadence.py`. Формулы используют обозначения, введённые перед таблицами.